



ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ
ΣΧΟΛΗ ΗΛΕΚΤΡΟΛΟΓΩΝ ΜΗΧΑΝΙΚΩΝ ΚΑΙ ΜΗΧΑΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ
ΤΟΜΕΑΣ

Τμηματοποίηση Πλακούντα σε MRI με τεχνικές Βαθιάς Μάθησης

Μελέτη και υλοποίηση

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΓΡΗΓΟΡΙΟΥ ΤΣΕΝΟΥ



Επιβλέπων: Γεώργιος Ματσόπουλος
Καθηγητής, Ε.Μ.Π.

Αθήνα, Φεβρουάριος 2026



Τμηματοποίηση Πλακώντα σε MRI με τεχνικές Βαθιάς Μάθησης

Μελέτη και υλοποίηση

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

του

ΓΡΗΓΟΡΙΟΥ ΤΣΕΝΟΥ

Επιβλέπων: Γεώργιος Ματσόπουλος
Καθηγητής, Ε.Μ.Π.

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή την 22α Φεβρουαρίου 2026.

(Υπογραφή)

(Υπογραφή)

(Υπογραφή)

.....
Γεώργιος Ματσόπουλος
Καθηγητής, Ε.Μ.Π.

.....
Παναγιώτης Τσανάκας
Επίκουρος Καθηγητής

.....
Γεώργιος Γεωργίου
Επιστ. Συνεργάτης



Copyright © – All rights reserved. Με την επιφύλαξη παντός δικαιώματος.

Γρηγόριος Τσένος, 2026.

Απαγορεύεται η αντιγραφή, αποθήκευση και διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμήματος αυτής, για εμπορικό σκοπό. Επιτρέπεται η ανατύπωση, αποθήκευση και διανομή για σκοπό μη κερδοσκοπικό, εκπαιδευτικής ή ερευνητικής φύσης, υπό την προϋπόθεση να αναφέρεται η πηγή προέλευσης και να διατηρείται το παρόν μήνυμα.

Το περιεχόμενο αυτής της εργασίας δεν απηχεί απαραίτητα τις απόψεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

ΔΗΛΩΣΗ ΜΗ ΛΟΓΟΚΛΟΠΗΣ ΚΑΙ ΑΝΑΛΗΨΗΣ ΠΡΟΣΩΠΙΚΗΣ ΕΥΘΥΝΗΣ

Με πλήρη επίγνωση των συνεπειών του νόμου περί πνευματικών δικαιωμάτων, δηλώνω ενυπογράφως ότι είμαι αποκλειστικός συγγραφέας της παρούσας Πτυχιακής Εργασίας, για την ολοκλήρωση της οποίας κάθε βοήθεια είναι πλήρως αναγνωρισμένη και αναφέρεται λεπτομερώς στην εργασία αυτή. Έχω αναφέρει πλήρως και με σαφείς αναφορές, όλες τις πηγές χρήσης δεδομένων, απόψεων, θέσεων και προτάσεων, ιδεών και λεκτικών αναφορών, είτε κατά κυριολεξία είτε βάσει επιστημονικής παράφρασης. Αναλαμβάνω την προσωπική και ατομική ευθύνη ότι σε περίπτωση αποτυχίας στην υλοποίηση των ανωτέρω δηλωθέντων στοιχείων, είμαι υπόλογος έναντι λογοκλοπής, γεγονός που σημαίνει αποτυχία στην Πτυχιακή μου Εργασία και κατά συνέπεια αποτυχία απόκτησης του Τίτλου Σπουδών, πέραν των λοιπών συνεπειών του νόμου περί πνευματικών δικαιωμάτων. Δηλώνω, συνεπώς, ότι αυτή η Πτυχιακή Εργασία προετοιμάστηκε και ολοκληρώθηκε από εμένα προσωπικά και αποκλειστικά και ότι, αναλαμβάνω πλήρως όλες τις συνέπειες του νόμου στην περίπτωση κατά την οποία αποδειχθεί, διαχρονικά, ότι η εργασία αυτή ή τμήμα της δεν μου ανήκει διότι είναι προϊόν λογοκλοπής άλλης πνευματικής ιδιοκτησίας.

(Υπογραφή)

.....
Γρηγόριος Τσένος

22 Σεπτεμβρίου 2020

Περίληψη

Ένα σύστημα ομότιμων κόμβων αποτελείται από ένα σύνολο αυτόνομων υπολογιστικών κόμβων στο Διαδίκτυο, οι οποίοι συνεργάζονται με σκοπό την ανταλλαγή δεδομένων. Στα συστήματα ομότιμων κόμβων που χρησιμοποιούνται ευρέως σήμερα, η αναζήτηση πληροφορίας γίνεται με χρήση λέξεων κλειδιών. Η ανάγκη για πιο εκφραστικές λειτουργίες, σε συνδυασμό με την ανάπτυξη του Σημασιολογικού Ιστού, οδήγησε στα συστήματα ομότιμων κόμβων βασισμένα σε σχήματα. Στα συστήματα αυτά κάθε κόμβος χρησιμοποιεί ένα σχήμα με βάση το οποίο οργανώνει τα τοπικά διαθέσιμα δεδομένα. Για να είναι δυνατή η αναζήτηση δεδομένων στα συστήματα αυτά υπάρχουν δύο τρόποι. Ο πρώτος είναι όλοι οι κόμβοι να χρησιμοποιούν το ίδιο σχήμα κάτι το οποίο δεν είναι ευέλικτο. Ο δεύτερος τρόπος δίνει την αυτονομία σε κάθε κόμβο να επιλέγει όποιο σχήμα θέλει και απαιτεί την ύπαρξη κανόνων αντιστοίχισης μεταξύ των σχημάτων για να μπορούν να αποτιμώνται οι ερωτήσεις. Αυτός ο τρόπος προσφέρει ευελιξία όμως δεν υποστηρίζει την αυτόματη δημιουργία και τη δυναμική ανανέωση των κανόνων, που είναι απαραίτητες για ένα σύστημα ομότιμων κόμβων.

Στόχος της διπλωματικής εργασίας είναι η ανάπτυξη ενός συστήματος ομότιμων κόμβων βασισμένο σε σχήματα το οποίο (α) θα επιτρέπει μια σχετική ευελιξία στην χρήση των σχημάτων και (β) θα δίνει την δυνατότητα μετασχηματισμού ερωτήσεων χωρίς την ανάγκη διατύπωσης κανόνων αντιστοίχισης μεταξύ σχημάτων, χρησιμοποιώντας κόμβους με σχήματα RDF που αποτελούν υποσύνολα-όψεις ενός βασικού σχήματος (καθολικό σχήμα).

Λέξεις Κλειδιά

Σύστημα ομότιμων κόμβων, Σύστημα ομότιμων κόμβων βασισμένο σε σχήματα, Σημασιολογικός Ιστός, RDF/S, RQL, Jxta

Abstract

A peer-to-peer system is a set of autonomous computing nodes (the peers) which cooperate in order to exchange data. The peers in the peer-to-peer systems that are widely used today, rely on simple keyword selection in order to search for data. The need for richer facilities in exchanging data, as well as, the evolution of the Semantic Web, led to the evolution of the schema-based peer-to-peer systems. In those systems every node uses a schema to organize the local data. So there are two ways in order for data search to be feasible. The first but not so flexible way implies that every node uses the same schema. The second way gives every node the flexibility to choose a schema according with its needs, but on the same time requires the existence of mapping rules in order for queries to be replied. This way though, doesn't offer automatic creation and dynamic renewal of the mapping rules which would be essential for peer-to-peer systems.

This diploma thesis aims to the development of a schema-based peer-to-peer system that allows a certain flexibility for schema selection and on the same time enables query transformation without the use of mapping rules. The peers use RDF schemas that are subsets (views) of a big common schema called global schema.

Keywords

Peer-to-peer, Schema-based peer-to-peer, Semantic Web, RDF/S, RQL, Jxta

στον Πατέρα μου και στην Μητέρα μου

Ευχαριστίες

Θα ήθελα καταρχήν να ευχαριστήσω τον καθηγητή κ. Ματσόπουλο Γεώργιο για την επίβλεψη αυτής της διπλωματικής εργασίας και για την ευκαιρία που μου έδωσε να ερευνήσω ένα πεδίο με τόσο μεγάλο ερευνητικό ενδιαφέρον. Κάτα την εκπόνηση της εργασίας έλαβα πολύτιμη καθοδήγηση και σχόλια από τα μέλη του εργαστηρίου του κου Ματσόπουλου, και ειδικότερα από τον Υπ.Διδάκτορα Γεωργά Κωνσταντίνο και τον Διδάκτορα Μπρώμη Κωνσταντίνο. Τέλος θα ήθελα να ευχαριστήσω τους γονείς μου για την καθοδήγηση και την ηθική συμπαράσταση που μου προσέφεραν όλα αυτά τα χρόνια.

Αθήνα, Δεκέμβριος 2025

Γρηγόριος Τσένος

Περιεχόμενα

Περίληψη	1
Abstract	3
Ευχαριστίες	7
Πρόλογος	19
1 Εισαγωγή	21
1.1 Συνοπτική Εισαγωγή	21
1.2 Αντικείμενο της διπλωματικής	22
1.3 Οργάνωση του τόμου	22
I Θεωρητικό Μέρος	25
2 Τμηματοποίηση Ιατρικών Εικόνων και Μαγνητική Τομογραφία	27
2.1 Ο πλακούντας: ανατομία, ανάπτυξη και λειτουργίες	27
2.2 Η τμηματοποίηση ως υπολογιστικό πρόβλημα	28
2.3 Ιδιαιτερότητες τμηματοποίησης πλακούντα σε MRI	29
2.4 Μαγνητική Τομογραφία MRI	29
2.4.1 Ανομοιογένεια έντασης και διόρθωση bias field	30
2.5 Συνήθη βήματα προεπεξεργασίας για τμηματοποίηση MRI	30
2.6 Μετρικές αξιολόγησης τμηματοποίησης	31
2.6.1 Συντελεστής Dice (DSC)	31
2.6.2 Intersection over Union (IoU/Jaccard)	31
2.7 Σύνοψη	31
3 Μηχανική Μάθηση και Σύγχρονα Μοντέλα για Τμηματοποίηση	33
3.1 Επιβλεπόμενη μάθηση για τμηματοποίηση	33
3.2 Συνελκτικά Νευρωνικά Δίκτυα (CNNs)	33
3.2.1 Η συνέλιξη σε 2D/3D δεδομένα και η έννοια του receptive field	34
3.2.2 Αρχιτεκτονικές πυκνής πρόβλεψης: FCN, encoder-decoder και U-shaped σχεδίαση	34
3.2.3 Κανονικοποίηση και σταθεροποίηση εκπαίδευσης	34
3.2.4 Προσοχή και CNNs: Attention U-Net	35
3.2.5 Πλεονεκτήματα και περιορισμοί των CNNs	35

3.3	Μοντέλα Attention και Transformers	35
3.3.1	Βασικός μηχανισμός self-attention	35
3.3.2	Self-Attention και Εικόνες: προκλήσεις και λύσεις	36
3.3.3	Μείωση κόστους: ιεραρχία, τοπικά παράθυρα και προσεγγίσεις γραμμικής προσοχής	36
3.3.4	Υβριδικά Transformer-U-shape μοντέλα	36
3.4	Μοντέλα Χώρου Καταστάσεων (State Space Models) και Mamba	36
3.4.1	Δομημένα Μοντέλα Χώρου Καταστάσεων (Structured SSMS) και Μοντελοποίηση Μακρινών Εξαρτήσεων	37
3.4.2	Mamba: Επιλεκτικά Μοντέλα Χώρου Καταστάσεων και Γραμμική Κλιμάκωση	37
3.4.3	Εφαρμογή SSMS/Mamba σε 3D Τμηματοποίηση	38
3.4.4	Συγκριτική Επισκόπηση	38
3.5	Βελτιστοποίηση και πρακτικές εκπαίδευσης	38
4	Αρχιτεκτονικές Τμηματοποίησης που Χρησιμοποιήθηκαν	41
4.1	Το πλαίσιο MONAI	41
4.1.1	Υλοποίηση μοντέλων στην παρούσα εργασία	41
4.2	Οικογένειες μοντέλων που συγκρίνονται	42
4.3	UNet και 3D U-Net	42
4.4	DynUNet	43
4.5	SegResNet: υπολειμματικό encoder-decoder	43
4.6	AttentionUnet: προσοχή στις skip connections	43
4.7	UNETR: ViT encoder με U-shaped decoder	44
4.8	SwinUNETR: ιεραρχικός Swin encoder	44
4.9	SegMamba: Mamba/SSM blocks σε U-shape σχεδίαση	44
4.10	Συζήτηση: αναμενόμενοι συμβιβασμοί	45
II	Πρακτικό Μέρος	47
5	Πειραματική Αξιολόγηση και Αποτελέσματα	49
5.1	Στόχοι αξιολόγησης και αρχές σύγκρισης	49
5.2	Υλοποίηση και λογισμικό	50
5.3	Σύνολο δεδομένων και διαχωρισμός	50
5.4	Αρχιτεκτονικές και πειραματικά σενάρια	50
5.4.1	Αρχιτεκτονικές υπερπαράμετροι ανά μοντέλο	51
5.5	Υπολογιστικό περιβάλλον και εκτέλεση πειραμάτων	52
5.6	Οργάνωση δεδομένων και ροή φόρτωσης	52
5.7	Ανάλυση στοίβας προεπεξεργασίας	52
5.7.1	Γεωμετρική εναρμόνιση και σταθεροποίηση εισόδου	52
5.7.2	Κανονικοποίηση εντάσεων	53
5.7.3	Περιορισμός πεδίου (POI) με foreground cropping	53
5.7.4	Σταθεροποίηση διαστάσεων για συμβατότητα μοντέλων	53

5.8 Δειγματοληψία patches και επαύξηση δεδομένων	53
5.9 Συνάρτηση κόστους και βελτιστοποίηση	54
5.9.1 Κριτήριο εκπαίδευσης	54
5.10 Επικύρωση και διαδικασία inference	54
5.10.1 Sliding Window Inference (SWI)	54
5.10.2 EMA (Exponential Moving Average)	54
5.11 Βελτιστοποίηση και Scheduler	54
5.11.1 Optimizer	54
5.11.2 Scheduler	54
6 Αποτελέσματα Πειραματικής Αξιολόγησης	57
6.1 Παρουσίαση αποτελεσμάτων	57
6.2 Συνοπτική κατάταξη και κύρια ευρήματα	58
6.3 Καμπύλες εκπαίδευσης και σταθερότητα σύγκλισης	59
6.4 Ποιοτική αξιολόγηση προβλέψεων	59
6.5 Συζήτηση και ερμηνεία	59
7 Παράδειγμα Πίνακα	65
7.1 Συμπεράσματα	65
7.2 Μελλοντικές Επεκτάσεις	65
8 Παράδειγμα Μαθηματικών Σχέσεων – Εκφράσεων και Αλγορίθμων	67
8.1 Συμπεράσματα	67
8.2 Μελλοντικές Επεκτάσεις	67
III Επίλογος	69
9 Επίλογος	71
9.1 Συμπεράσματα	71
9.2 Μελλοντικές Επεκτάσεις	71
Παραρτήματα	73
A' Παράδειγμα Παραρτήματος	75
A'.1 Πρώτη ενότητα	75
A'.2 Μελλοντικές Επεκτάσεις	75
B' Απόδειξη της σχέσης (8.1)	77
B'.1 Ανάλυση - περιγραφή αρχιτεκτονικής	77
B'.1.1 Διαχωρισμός υποσυστημάτων	77
B'.1.2 Περιγραφή υποσυστημάτων	78
Γ' Παραδείγματα Βιβλιογραφικών Αναφορών	79
Δ' Δημιουργία Ευρετηρίου	81

Ε΄ Εισαγωγή Εικόνων	83
Βιβλιογραφία	89
Συντομογραφίες - Αρκτικόλεξα - Ακρωνύμια	91
Απόδοση ξενόγλωσσων όρων	93

Κατάλογος Σχημάτων

2.1	Αριστερά : ενδεικτική δισδιάστατη τομή (slice) MRI με την επισήμανση (πράσινο) του πιακούντα. Δεξιά : τρισδιάστατη αναπαράσταση της αντίστοιχης μάσκας τμηματοποίησης (πράσινο) και της θέσης της τομής στον όγκο.	30
4.1	Δομή αρχιτεκτονικής U-net	42
4.2	Μηχανισμός residual connection στην αρχιτεκτονική ResNet [1]	43
6.1	59
6.2	60
6.3	60
B'.1	Προσομοίωση Πύλης NOR	77

Κατάλογος Εικόνων

6.1	Attention U-Net	61
6.2	DynUNet	61
6.3	SwinUNETR	61
6.4	SegResNet 1 (No of Filters = 64)	62
6.5	SegResNet 2 (No of Filters = 32)	62
6.6	U-Net	62
6.7	UNETR	63
6.8	SegMamba 1 (5 layers)	63
6.9	SegMamba 2 (4 layers)	63

Κατάλογος Πινάκων

6.1	Αποτελέσματα ανά αρχιτεκτονική στο validation set.	58
7.1	Πίνακας αλήθειας της λογικής συνάρτησης F	66
A'.1	Πίνακας αλήθειας της λογικής συνάρτησης F	76

Πρόλογος

Το υπολογιστικό μέρος της εργασίας υλοποιήθηκε και εκτελέστηκε στη πλατφόρμα Kaggle (Kaggle Notebooks). Το θεωρητικό υπόβαθρο βασίστηκε σε μελέτη της σχετικής βιβλιογραφίας.

Κεφάλαιο 1

Εισαγωγή

Η ιατρική απεικόνιση αποτελεί αναπόσπαστο μέρος της σύγχρονης κλινικής πρακτικής και της βιοϊατρικής έρευνας, καθώς επιτρέπει τη μη επεμβατική παρατήρηση ανατομικών δομών και φυσιολογικών διεργασιών. Πέρα όμως από την οπτική επιβεβαίωση ή περιγραφική αξιολόγηση, σε πολλές εφαρμογές είναι απαραίτητη η *ποσοτικοποίηση*: η εξαγωγή μετρήσιμων μεγεθών (π.χ. όγκοι, σχήματα, σχέσεις γειτονικών ιστών), που στη συνέχεια μπορούν να συσχετισθούν με κλινικά ευρήματα ή να αξιοποιηθούν σε συστήματα υποβοήθησης διάγνωσης.

1.1 Συνοπτική Εισαγωγή

Κεντρικό βήμα για την ποσοτικοποίηση αποτελεί η **τμηματοποίηση** (segmentation) μιας ιατρικής εικόνας ή ενός ογκομετρικού δεδομένου. Με τον όρο τμηματοποίηση εννοούμε την ανάθεση ετικέτας σε κάθε (ογκομετρικό) εικονοστοιχείο (pixel/voxel), ώστε να διαχωριστεί η *περιοχή ενδιαφέροντος* (Region of Interest, ROI) από το υπόλοιπο υπόβαθρο. Στην πράξη, η τμηματοποίηση επιστρέφει μία *μάσκα* (mask) με την ίδια διάσταση όπως η είσοδος, η οποία κωδικοποιεί το 'ανήκει/δεν ανήκει' (δυαδική τμηματοποίηση) ή/και πολλαπλές κλάσεις (πολυκλασική τμηματοποίηση). Η τμηματοποίηση είναι η βάση για τον υπολογισμό όγκου, την εκτίμηση μορφολογικών χαρακτηριστικών, την ανάλυση χωρικής ετερογένειας, αλλά και για πιο σύνθετες ροές εργασίας, όπως εξαγωγή χαρακτηριστικών (radiomics) ή καθοδήγηση επεμβάσεων.

Στο πλαίσιο της μαιευτικής απεικόνισης, ιδιαίτερο ενδιαφέρον παρουσιάζει ο **πλακούντας**, ένα λειτουργικά κρίσιμο όργανο που συνδέει μητέρα και έμβρυο. Η **αυτόματη τμηματοποίηση πλακούντα** σε δεδομένα MRI επιτρέπει επαναλήψιμες και αντικειμενικές μετρήσεις (π.χ. όγκος/σχήμα), καθώς και τη συστηματική σύγκριση μεταξύ εξετάσεων ή πρωτοκόλλων. Ωστόσο, η τμηματοποίηση πλακούντα σε MRI είναι απαιτητικό πρόβλημα: τα δεδομένα συχνά επηρεάζονται από κίνηση μητέρας/εμβρύου, ανομοιογένειες έντασης, περιορισμένη αντίθεση στα όρια οργάνου-υποβάθρου και μεγάλη διακύμανση σε μέγεθος, σχήμα και θέση. Προγενέστερες προσεγγίσεις περιλάμβαναν κλασικούς ταξινομητές ή ελάχιστα/μερικώς διαδραστικές μεθόδους, ενώ έχουν παρουσιαστεί και τρόποι για αντιμετώπιση σε περίπτωση που αλλοιωθεί η εικόνα λόγω κίνησης. [2][3][4].

Η χειροκίνητη τμηματοποίηση, αν και θεωρείται σημείο αναφοράς, είναι χρονοβόρα και εμφανίζει διακύμανση μεταξύ παρατηρητών, κάτι που επηρεάζει τόσο την αξιολόγηση όσο και

την κλινική αξιοποίηση. Για τον λόγο αυτό, τα τελευταία χρόνια κυριαρχούν μέθοδοι **Βαθιάς Μάθησης** (Deep Learning) για τμηματοποίηση ιατρικών εικόνων, με αρχιτεκτονικές τύπου UNet να αποτελούν θεμελιώδη επιλογή [5]. Παράλληλα, μοντέλα με μηχανισμούς attention και Transformers έχουν δείξει ιδιαίτερα ισχυρή ικανότητα μοντελοποίησης διευκολύνοντας την συσχέτιση μακρινών εικονοστοιχείων (global context) [6, 7, 8]. Πρόσφατα, τα **Μοντέλα Χώρου και Κατάστασης** (State Space Models, SSMs) και ειδικότερα το Mamba εισάγουν μία εναλλακτική προσέγγιση μακράς εμβέλειας, με στόχο υψηλή αποδοτικότητα σε μνήμη και χρόνο [9], και έχουν προταθεί υβριδικά μοντέλα τμηματοποίησης όπως το SegMamba [10]. (Λεπτομέρειες στα κεφάλαια 2,3,4)

1.2 Αντικείμενο της διπλωματικής

Αντικείμενο της παρούσας διπλωματικής εργασίας είναι η **συστηματική μελέτη, υλοποίηση και συγκριτική αξιολόγηση** μοντέλων τμηματοποίησης πλακούντα από ογκομετρικά δεδομένα MRI, με χρήση της βιβλιοθήκης MONAI [11]. Η εργασία επικεντρώνεται σε ένα δίκαιο πειραματικό πρωτόκολλο, όπου τα μοντέλα εκπαιδεύονται και αξιολογούνται υπό *ιδιες* συνθήκες (ίδιο seed, ίδια προεπεξεργασία, ίδιοι βελτιστοποιητές, κριτήρια, σχήματα learning rate, αριθμός εποχών και συνολικό πείραμα), ώστε οι διαφορές στην επίδοση να αποδίδονται σε μεγαλύτερο βαθμό στην αρχιτεκτονική.

Συγκεκριμένα, εξετάζονται οι παρακάτω αρχιτεκτονικές:

- **Συνελικτικά μοντέλα τύπου UNet:** UNet [5], DynUNet (δυναμική παραλλαγή σχεδιασμένη με αρχές αυτο-διαμόρφωσης), SegResNet [12], καθώς και AttentionUnet [13].
- **Υβριδικά μοντέλα με Transformers:** UNETR [7] και SwinUNETR [8].
- **Μοντέλο βασισμένο σε SSM/Mamba:** SegMamba [10].

Για την αξιολόγηση χρησιμοποιείται κυρίως η **μετρική Dice** (γνωστή και ως DSC) και συμπληρωματικά ο **Intersection over Union** (IoU/Jaccard). Στόχος δεν είναι απλώς η καταγραφή μιας μέγιστης επίδοσης, αλλά και η **εξαγωγή συμπερασμάτων** για τα πλεονεκτήματα/μειονεκτήματα κάθε οικογένειας αρχιτεκτονικών (καθαρά συνελικτικές, Transformer-ενισχυμένες, SSM-βασισμένες) στο συγκεκριμένο πρόβλημα.

1.3 Οργάνωση του τόμου

Η διάρθρωση της διπλωματικής έχει ως εξής:

- Στο **Κεφάλαιο 2** παρουσιάζονται οι βασικές έννοιες που απαιτούνται για την ποσοτική αξιολόγηση του πλακούντα σε MRI: συνοπτικά στοιχεία ανατομίας/ανάπτυξης/λειτουργιών και κλινικής σημασίας του πλακούντα, η διατύπωση της *τμηματοποίησης* ως υπολογιστικού προβλήματος, οι ιδιαιτερότητες της τμηματοποίησης πλακούντα σε ογκομετρικά δεδομένα MRI, βασικές αρχές της MRI, συνήθη βήματα προεπεξεργασίας, καθώς και οι μετρικές αξιολόγησης (Dice/DSC, IoU).

- Στο **Κεφάλαιο 3** παρουσιάζεται το θεωρητικό υπόβαθρο της Μηχανικής Μάθησης και της Βαθιάς Μάθησης για τμηματοποίηση: επιβλεπόμενη μάθηση και συναρτήσεις κόστους, CNNs, Transformers και SSM/Mamba, καθώς και βασικές πρακτικές εκπαίδευσης/βελτιστοποίησης (π.χ. βελτιστοποιητές, learning rate schedulers, κανονικοποίηση).
- Στο **Κεφάλαιο 4** περιγράφονται οι αρχιτεκτονικές των επτά μοντέλων που χρησιμοποιήθηκαν (UNet, DynUNet, SegResNet, AttentionUnet, UNETR, SwinUNETR, SegMamba), καθώς και οι κύριες σχεδιαστικές επιλογές και οι αναμενόμενοι συμβιβασμοί τους στην 3D τμηματοποίηση ιατρικών δεδομένων.
- Στα επόμενα κεφάλαια (πειραματικό μέρος) παρουσιάζονται το σύνολο δεδομένων, το pipeline υλοποίησης και προεπεξεργασίας, το πρωτόκολλο εκπαίδευσης/αξιολόγησης, τα πειραματικά αποτελέσματα και η συζήτησή τους, και τέλος τα συμπεράσματα και οι μελλοντικές κατευθύνσεις.

Μέρος I

Θεωρητικό Μέρος

Κεφάλαιο 2

Τμηματοποίηση Ιατρικών Εικόνων και Μαγνητική Τομογραφία

Ο πλακούντας αποτελεί ένα προσωρινό αλληλάκρισιμο όργανο της κύησης, το οποίο λειτουργεί ως επιφάνεια διεπαφής μεταξύ μητέρας και εμβρύου, επιτρέποντας την ανταλλαγή αερίων, θρεπτικών συστατικών και μεταβολισμού ουσιών, ενώ παράλληλα επιτελεί σημαντικούς ενδοκρινικούς και ανοσολογικούς ρόλους [14, 15, 16]. Ο πλακούντας, επίσης, κρατά προσκολλημένο το έμβρυο με το τοίχωμα της μήτρας όπου επιτελεί και αναπνευστική επιφάνεια για το έμβρυο. Η λειτουργία του πλακούντα σχετίζεται άμεσα με την ομαλή έκβαση της κύησης, και η δυσλειτουργία του έχει συσχετιστεί με σοβαρές μαιευτικές επιπλοκές, όπως προεκλαμψία, υπολειπόμενη ανάπτυξη εμβρύου (FGR), αποβολές και ενδομήτριο θάνατο του εμβρύου.

Σε αυτό το πλαίσιο, η ιατρική απεικόνιση – και ειδικότερα η Μαγνητική Τομογραφία (MRI) – μπορεί να υποστηρίξει την ποσοτική αξιολόγηση του πλακούντα. Ωστόσο, για να εξαχθούν αξιόπιστες μετρήσεις (π. χ. όγκος, σχήμα, μορφολογικοί δείκτες ή/και χαρακτηριστικά υφής), απαιτείται πρώτα ο ακριβής διαχωρισμός του πλακούντα από το υπόδαθρο: η **τμηματοποίηση** (segmentation). Στην παρούσα εργασία, στόχος είναι η τμηματοποίηση του πλακούντα σε ογκομετρικά δεδομένα MRI, δηλαδή η παραγωγή μιας δυαδικής μάσκας (πλακούντας έναντι υποδάθρου) για κάθε εικόνα.

2.1 Ο πλακούντας: ανατομία, ανάπτυξη και λειτουργίες

Ο πλακούντας αναπτύσσεται από την τροφόβλαστη της περιφέρειας της βλαστοκύστης, όπου συμβαίνει η εμφύτευση. Η εμφύτευση λαμβάνει χώρα επτά με δώδεκα ημέρες μετά τη γονιμοποίηση [17]. Από ανατομικής άποψης, στον πλακούντα διακρίνεται:

- το **χοριακό πέταλο** (chorionic plate) (εμβρυική πλευρά), από όπου εκφύονται οι χοριακές λάχνες και το δίκτυο αγγείων του εμβρύου,
- το **φθαρτικό πέταλο** (basal plate/decidua) (μητρική πλευρά), το οποίο συνδέεται με το τοίχωμα της μήτρας. Γίνεται εμφανές αφού κατά τον τοκετό πραγματοποιείται διαχωρισμός του πλακούντα από το σώμα της μήτρας μέσω αυτού,
- ο **μεσολάχνιος χώρος** (intervillous space), όπου κυκλοφορεί μητρικό αίμα, διαχωρίζεται η εμβρυική κυκλοφορία από τις δεξαμενές του μητρικού αίματος, και πραγμα-

τοποιείται η κύρια μεταφορά οξυγόνου, θρεπτικών συστατικών και μεταβολιτών μεταξύ μητέρας και εμβρύου.

Οι χοριακές λάχνες, με υψηλή πυκνότητα σε τροφοβλαστικούς πληθυσμούς (με κυρίαρχο το syncytiotrophoblast), αποτελούν τον κύριο συντελεστή στην ανταλλαγή συστατικών μεταξύ μητέρας και εμβρύου [16, 15].

Καθοριστικό βήμα στην ορθή πλακουντοποίηση είναι η **αναδιαμόρφωση των μητρικών σπειροειδών αρτηριών**, μέσω εισβολής εξωλάχνιων τροφοβλάστων (extravillous trophoblast) στον φθαρτό της μήτρας, ώστε να εξασφαλιστεί σταθερή αιμάτωση προς τον πλακούντα. Η ελαττωματική πλακουντοποίηση έχει προταθεί ως κοινός παθοφυσιολογικός μηχανισμός πίσω από τις διάφορες επιπλοκές της κύησης (π. χ. προεκλαμψία, αποκόλληση πλακούντα, fetal growth restriction) [18, 19].

Λειτουργικά, ο πλακούντας:

- εξασφαλίζει **μεταφορά** οξυγόνου, ηλεκτρολυτών και θρεπτικών ουσιών (νερό, γλυκόζη, αμινοξέα, λιπίδια, βιταμίνες) και συμβάλλει στην **απομάκρυνση** μεταβολικών προϊόντων όπως ουρεία, ουρικό οξύ και άλλων αποβλήτων [20],
- δρα ως **ενδοκρινικό όργανο** (παραγωγή ορμονών που ρυθμίζουν την κύηση και τον μεταβολισμό της μητέρας),
- συμμετέχει στην **ανοσολογική ανοχή** και στη ρύθμιση της διεπαφής μεταξύ μητέρας και εμβρύου.

Συνεπώς, ο πλακούντας δεν είναι απλώς «φίλτρο», αλλά ένα πολυλειτουργικό όργανο με δυναμική εξέλιξη και προσαρμογή κατά την κύηση [14, 15]. Η μεταφορά, ωστόσο, δεν αφορά μόνο χρήσιμες και απαραίτητες ουσίες. Επιβλαβείς παράγοντες μπορούν να περάσουν, όπως ψυχοδραστικές ουσίες, μονοξείδιο του άνθρακα, διάφοροι λοιμώδεις παράγοντες κ.α. [20].

Η παραπάνω φυσιολογική πολυπλοκότητα εξηγεί γιατί η **ποσοτική** αξιολόγηση του πλακούντα (δομή/μορφολογία, χωρική κατανομή, όγκος) αποτελεί ενεργό ερευνητικό πεδίο. Η Μαγνητική (MRI) προσφέρει υψηλή αντίθεση μαλακών ιστών και τρισδιάστατη πληροφορία, όμως η ποσοτικοποίηση προϋποθέτει αξιόπιστο *ορισμό της περιοχής του πλακούντα* μέσα στον όγκο, δηλαδή ακριβής τμηματοποίηση. Η ανάγκη αυτή αποτυπώνεται και σε μελέτες που αναπτύσσουν αυτοματοποιημένους αλγορίθμους για τμηματοποίηση πλακούντα/μήτρας σε MRI όπου αναφέρεται άμεσα η σχέση της τμηματοποίησης με ορθή και συνεπή υπολογισμό του όγκου [4].

2.2 Η τμηματοποίηση ως υπολογιστικό πρόβλημα

Σε ένα τυπικό σενάριο **δυναμικής τμηματοποίησης**, η είσοδος είναι ένας όγκος $X \in \mathbb{R}^{H \times W \times D}$ και η έξοδος είναι μια μάσκα $Y \in \{0, 1\}^{H \times W \times D}$ που υποδηλώνει για κάθε voxel αν ανήκει στην κλάση ενδιαφέροντος. Η μάθηση διατυπώνεται συνήθως ως **επιβλεπόμενη** μάθηση: διαθέτουμε σύνολο ζευγών (X_i, Y_i) και επιδιώκουμε μοντέλο f_θ ώστε $f_\theta(X_i) \approx Y_i$.

Η **μάσκα τμηματοποίησης** (segmentation mask) είναι μια εικόνα/όγκος *ιδιων διαστάσεων* με την είσοδο, όπου κάθε pixel/voxel παίρνει τιμή 1 (λευκό) αν ανήκει στην κλάση ενδιαφέροντος (π.χ. πλακούντας) και 0 (μαύρο) διαφορετικά.

Η τμηματοποίηση διαφέρει από την ταξινόμηση εικόνας (Image Classification) στο γεγονός ότι η έξοδος είναι **πυκνή** πρόβλεψη (ανά pixel/voxel) και όχι μία ετικέτα ανά εικόνα.

Στην 3D τμηματοποίηση, οι υπολογιστικές απαιτήσεις αυξάνονται σημαντικά σε σχέση με το πλήθος των voxels. Έτσι, συχνά χρησιμοποιούνται στρατηγικές **patch-based** εκπαίδευσης και **sliding-window inference** (στο Κεφάλαιο 3 αναλύονται οι αντίστοιχες πρακτικές), έτσι ώστε να είναι εφικτή η εκπαίδευση/πρόβλεψη σε μνήμη GPU.

2.3 Ιδιαιτερότητες τμηματοποίησης πλακούντα σε MRI

Η τμηματοποίηση πλακούντα σε MRI είναι απαιτητική για λόγους που σχετίζονται τόσο με τη φυσιολογία όσο και με τη διαδικασία λήψης:


- **Μεγάλη μορφολογική μεταβλητότητα:** μέγεθος, σχήμα και θέση του πλακούντα μεταβάλλονται σημαντικά.
- **Περιορισμένη αντίθεση** σε ορισμένες ακολουθίες, ιδιαίτερα στα όρια πλακούντα και παρακείμενων ιστών.
- **Ανισορροπία κλάσεων:** στα περισσότερα slices ο πλακούντας καταλαμβάνει μικρό μέρος του όγκου, κάτι που δυσκολεύει τη μάθηση και φέρει την ανάγκη για στοχευμένη δειγματοληψία και μεθοδολογία (λεπτομερώς παρακάτω 2.5) [21, 22, 23].
- **Κίνηση** (μητέρα/εμβρύου) που οδηγεί σε artifacts, διαστρεβλώσεις και θολή εικόνα.
- **Ανομοιογένεια έντασης** (bias field) που επηρεάζει την εμφάνιση ίδιου ιστού σε διαφορετικές περιοχές.

Σχετικές εργασίες έχουν δείξει ότι ακόμη και με προσεκτική χειροκίνητη τμηματοποίηση η διαδικασία είναι χρονοβόρα και εμφανίζει ασυνέπεια ως προς διαφορετικούς παρατηρητές. Παράλληλα, έχουν παρουσιαστεί μέθοδοι αυτόματης/ημιαυτόματης τμηματοποίησης για πλακούντα σε MRI, συμπεριλαμβανομένων πλαισίων που αντιμετωπίζουν δεδομένα με θόρυβο [2, 3] καθώς και προσεγγίσεων βαθιάς μάθησης για τρισδιάστατη τμηματοποίηση πλακούντα και εκτίμηση όγκου [4, 24, 25].

2.4 Μαγνητική Τομογραφία MRI

Η Μαγνητική Τομογραφία (Magnetic Resonance Imaging, MRI) είναι τεχνική απεικόνισης που βασίζεται στο φαινόμενο του πυρηνικού μαγνητικού συντονισμού. Συνοπτικά, τα πρωτόνια (κυρίως του υδρογόνου) ευθυγραμμίζονται με το στατικό μαγνητικό πεδίο, διεγείρονται με ραδιοσυχνότητες, και η επιστροφή τους στην ισορροπία παράγει σήμα που καταγράφεται και αναδομείται σε εικόνα. Η αντίθεση μεταξύ ιστών εξαρτάται από παραμέτρους όπως οι χρόνοι χαλάρωσης T_1 και T_2 , καθώς και από τη διαμόρφωση των ακολουθιών λήψης. Αναλυτικότερη θεμελίωση παρέχεται σε κλασικά συγγράμματα [26, 27].

Για την τμηματοποίηση, η μαγνητική παρουσιάζει πλεονεκτήματα (υψηλή αντίθεση μαλακών ιστών, 3D πληροφορία), αλλά και προκλήσεις: θόρυβο, ανομοιογένειες έντασης, και



Σχήμα 2.1: Αριστερά: ενδεικτική δισδιάστατη τομή (slice) MRI με την επισήμανση (πράσινο) του πηλακούντια. Δεξιά: τρισδιάστατη αναπαράσταση της αντίστοιχης μάσκας τμηματοποίησης (πράσινο) και της θέσης της τομής στον όγκο.

μεταβολές μεταξύ σαρωτών/πρωτοκόλλων. Ειδικά σε απεικόνιση κύησης, η κίνηση αποτελεί συχνό πρόβλημα, επηρεάζοντας την ευκρίνεια και τη συνέπεια μεταξύ τομών [2].

2.4.1 Ανομοιογένεια έντασης και διόρθωση bias field

Η ανομοιογένεια έντασης (intensity non-uniformity) ή bias field είναι αργά μεταβαλλόμενη παραμόρφωση που οδηγεί σε διαφορετικές εντάσεις για τον ίδιο ιστό σε διαφορετικά σημεία του όγκου. Μία καθιερωμένη μέθοδος διόρθωσης είναι ο αλγόριθμος N4ITK [28], ο οποίος βελτιώνει προγενέστερες προσεγγίσεις και χρησιμοποιείται ευρέως ως προεπεξεργαστικό βήμα.

2.5 Συνήθη βήματα προεπεξεργασίας για τμηματοποίηση MRI

Αν και το ακριβές pipeline εξαρτάται από το πρόβλημα και το σύνολο δεδομένων, σε 3D MRI τμηματοποίηση εφαρμόζονται συχνά [29]:

- **Εναρμόνιση προσανατολισμού** (κοινός άξονας αναφοράς).

- **Επαναδειγματοληψία** (resampling) σε επιθυμητή χωρική ανάλυση (voxel spacing).
- **Κανονικοποίηση έντασης** (κλιμάκωση σε $[0, 1]$).
- **Περικοπή εικόνας** (π.χ. crop foreground) ώστε να μειωθεί το περιττό υπόβαθρο και η ανισορροπία κλάσεων.
- **Εμπλουτισμός δεδομένων** (augmentation) με τυχαίες περιστροφές/αντιστροφές/πα-ραμορφώσεις/θόρυβο.

Στόχος των παραπάνω είναι (α) η διευκόλυνση της εκπαίδευσης με σταθερότερα στατιστικά, (β) η κανονικοποίηση των δεδομένων και (γ) η βελτίωση της γενίκευσης του μοντέλου.

2.6 Μετρικές αξιολόγησης τμηματοποίησης

Για την αξιολόγηση δυαδικής τμηματοποίησης χρησιμοποιούνται μετρικές επικάλυψης μεταξύ πρόβλεψης P και αλήθειας G . Οι πιο διαδεδομένες είναι:

2.6.1 Συντελεστής Dice (DSC)

Ο συντελεστής Dice ορίζεται ως:

$$\text{DSC}(P, G) = \frac{2|P \cap G|}{|P| + |G|}.^1 \quad (2.1)$$

Η τιμή του βρίσκεται στο $[0, 1]$, όπου 1 δηλώνει τέλεια επικάλυψη.

2.6.2 Intersection over Union (IoU/Jaccard)

Ο δείκτης Jaccard ορίζεται ως:

$$\text{IoU}(P, G) = \frac{|P \cap G|}{|P \cup G|}. \quad (2.2)$$

Και εδώ οι τιμές είναι στο $[0, 1]$. Οι δύο μετρικές σχετίζονται μονοτονικά και συχνά αναφέρονται μαζί.

2.7 Σύνοψη

Στο κεφάλαιο αυτό παρουσιάστηκαν:

- βασικές έννοιες φυσιολογίας/ανάπτυξης του πλακούντα και η κλινική του σημασία,
- ο ρόλος της τμηματοποίησης ως υπολογιστικό πρόβλημα,
- οι ιδιαίτερες δυσκολίες της τμηματοποίησης πλακούντα σε MRI,
- βασικές αρχές της MRI που σχετίζονται με τη φύση των δεδομένων,
- και οι μετρικές αξιολόγησης που χρησιμοποιούνται στην παρούσα εργασία.

¹Ο τελεστής \cap υπολογίζει την τομή δύο συνόλων A και B που αποτελείται από τα κοινά στοιχεία τους.

Μηχανική Μάθηση και Σύγχρονα Μοντέλα για Τμηματοποίηση

Η αυτόματη τμηματοποίηση με σύγχρονες προσεγγίσεις βασίζεται κυρίως σε **επιβλεπόμενη** Μηχανική Μάθηση, όπου το μοντέλο εκπαιδεύεται σε ζεύγη ιατρικών εικόνων και των αντίστοιχων **μασκών τμηματοποίησης** που έχουν δημιουργηθεί χειροκίνητα από ειδικούς [30]. Η επιτυχία της Βαθιάς Μάθησης στην τμηματοποίηση οφείλεται στην ικανότητα της να μαθαίνει πλούσιες ιεραρχικές αναπαραστάσεις (απο απλά τοπικά χαρακτηριστικά έως πολύπλοκα χωρικά μοτίβα) από μεγάλα σύνολα δεδομένων, καθώς και στην αποδοτική βελτιστοποίηση με backpropagation. Για γενικότερο πλαίσιο στη Βαθιά Μάθηση, παραπέμπουμε σε κλασικές πηγές [30, 31, 32].

3.1 Επιβλεπόμενη μάθηση για τμηματοποίηση

Έστω ότι διαθέτουμε σύνολο εκπαίδευσης $\mathcal{D} = \{(X_i, Y_i)\}_{i=1}^N$, όπου X_i είναι MRI όγκος και Y_i η αντίστοιχη δυαδική μάσκα πλακούντα. Θέλουμε να βρούμε παραμέτρους θ ώστε το μοντέλο f_θ να ελαχιστοποιεί μία συνάρτηση απώλειας:

$$\theta^* = \arg \min_{\theta} \sum_{i=1}^N \mathcal{L}(f_\theta(X_i), Y_i). \quad (3.1)$$

Στην τμηματοποίηση, η επιλογή \mathcal{L} είναι καθοριστική. Η απλή binary cross-entropy είναι χρήσιμη ως per-voxel ταξινόμηση, όμως συχνά συνδυάζεται με απώλειες επικάλυψης (π.χ. Dice loss), ώστε να μετριάσει η ανισορροπία κλάσεων (το υπόβαθρο καταλαμβάνει μεγάλο μέρος των voxels) [33]. Μία γνωστή 3D αρχιτεκτονική που ανέδειξε τη χρησιμότητα απωλειών επικάλυψης είναι το V-Net [34].

3.2 Συνελικτικά Νευρωνικά Δίκτυα (CNNs)

Τα CNNs αποτελούν την κυρίαρχη οικογένεια μοντέλων για εικόνες, καθώς επεξεργάζονται εισόδους *δομημένες σε πλέγμα* και αξιοποιούν τη διαδικασία της **συνέλιξης** (convolution). Με κοινή χρήση βαρών σε όλο το πεδίο εισόδου, η ίδια ανίχνευση προτύπων εφαρμόζεται σε διαφορετικές χωρικές θέσεις, δηλαδή παρουσιάζουν **ισοδυναμία ως προς μετατοπίσεις** (translation equivariance) [35]. Οι συνέλιξεις λειτουργούν ως φίλτρα που ανιχνεύουν

τοπικά πρότυπα (άκρα, υφές, σχήματα), ενώ η ιεραρχική στοίβαξη πολλών στρωμάτων επιτρέπει την αναπαράσταση ολόενα και πιο σύνθετων δομών.

Στην πράξη, τα CNNs χρησιμοποιούνται ευρέως σε προβλήματα όρασης, επειδή μαθαίνουν ιεραρχικά χαρακτηριστικά και κλιμακώνονται αποτελεσματικά με το μέγεθος των δεδομένων εκπαίδευσης [36]. Στη συνέχεια, αρχιτεκτονικές με **υπολειμματικές συνδέσεις** (residual connections) επέτρεψαν την εκπαίδευση πολύ βαθιών δικτύων [1].

3.2.1 Η συνέλιξη σε 2D/3D δεδομένα και η έννοια του receptive field

Η βασική πράξη της συνέλιξης μπορεί να θεωρηθεί ως γραμμικός μετασχηματισμός με **κοινή χρήση βαρών** σε όλα τα χωρικά σημεία. Για 3D όγκους, μια 3D συνέλιξη εφαρμόζει πυρήνα K διαστάσεων $k_x \times k_y \times k_z$ και παράγει χαρακτηριστικά που κωδικοποιούν τοπικές χωρικές σχέσεις μέσα στον όγκο. Η τοπικότητα αυτή είναι ιδιαίτερα χρήσιμη στην τμηματοποίηση, όπου τα όρια ενός οργάνου καθορίζονται από *τοπικές* μεταβολές έντασης και υφής.

Καθώς το βάθος του δικτύου αυξάνεται, το **receptive field** ενός νευρώνα μεγαλώνει (μέσω διαδοχικών συνελιξεων και υποδειγματοληψιών), επιτρέποντας στο μοντέλο να ενσωματώνει ευρύτερο συμφραζόμενο (wider context). Παρ' όλα αυτά, η αύξηση αυτή είναι *έμμεση* και εξαρτάται από το βάθος και τη σχεδίαση του δικτύου.

3.2.2 Αρχιτεκτονικές πυκνής πρόδλεψης: FCN, encoder–decoder και U-shaped σχεδίαση

Η τμηματοποίηση απαιτεί **πυκνή** πρόδλεψη (ετικέτα ανά pixel/voxel). Μια θεμελιώδης ιδέα για αυτόν τον σκοπό είναι τα Fully Convolutional Networks (FCNs), τα οποία αντικαθιστούν τα πλήρως συνδεδεμένα στρώματα με συνελκτικά, ώστε το δίκτυο να παράγει χάρτες χαρακτηριστικών (feature maps) [37].

Στην ιατρική τμηματοποίηση, η αρχιτεκτονική U-Net είναι ιδιαίτερα επιδραστική, καθώς συνδυάζει:

- έναν **κωδικοποιητή** (encoder) που συμπιέζει την πληροφορία σε πολλαπλές κλίμακες (κωδικοποιώντας το «τι»),
- έναν **αποκωδικοποιητή** (decoder) που ανακατασκευάζει την ανάλυση (βρίσκοντας το «πού»),
- **συνδέσεις παράκαμψης** (skip connections) που μεταφέρουν λεπτομέρεια υψηλής ανάλυσης από τον κωδικοποιητή στον αποκωδικοποιητή, βελτιώνοντας την χωρική ακρίβεια [5].

Για ογκομετρικά δεδομένα, η λογική αυτή επεκτάθηκε σε 3D U-Net με 3D συνελιξεις, επιτρέποντας αξιοποίηση της πληροφορίας κατά μήκος όλων των αξόνων του όγκου [38].

3.2.3 Κανονικοποίηση και σταθεροποίηση εκπαίδευσης

Σε βαθιά δίκτυα, η σταθερότητα εκπαίδευσης επηρεάζεται από την κατανομή ενεργοποιήσεων. Η Batch Normalization είναι κλασική τεχνική επιτάχυνσης και σταθεροποίησης [39],

όμως στη 3D τμηματοποίηση το batch size είναι συχνά πολύ μικρό λόγω μνήμης. Σε τέτοιες περιπτώσεις, τεχνικές όπως η Group Normalization μπορεί να είναι πρακτικά πιο σταθερές [40].

3.2.4 Προσοχή και CNNs: Attention U-Net

Η συγκεκριμένη ‘προσοχή’ δεν ταυτίζεται απαραίτητα με τους Transformers. Στα CNN-βασισμένα μοντέλα, έχουν προταθεί **attention gates** που «φιλτράρουν» τις skip connections ώστε να τονίζουν περιοχές σχετικές με το ενδιαφερόμενο όργανο. Ένα κλασικό παράδειγμα είναι το Attention U-Net [13], το οποίο μπορεί να βελτιώσει την εστίαση σε μικρές ή πολύπλοκες δομές χωρίς να απαιτεί πλήρη self-attention σε όλο τον όγκο.

3.2.5 Πλεονεκτήματα και περιορισμοί των CNNs

Τα κύρια πλεονεκτήματα για τμηματοποίηση είναι:

- Υψηλή **αποδοτικότητα** (η συνέλιξη είναι υπολογιστικά ευνοϊκή).
- Έμφαση σε **τοπικά μορφολογικά στοιχεία**, χρήσιμα για ακριβή όρια.
- Ταχύτερα σε **μικρότερα σύνολα δεδομένων** σε σχέση με καθαρά Transformer μοντέλα.

Κύριος περιορισμός είναι ότι η **παγκόσμια πληροφορία** (global context) δεν είναι άμεσα διαθέσιμη: οι μακρινές χωρικές συσχετίσεις μοντελοποιούνται έμμεσα μέσω βάθους/υποδειγματοληψιών, και η αποτελεσματικότητα αυτής της διαδικασίας εξαρτάται έντονα από τη σχεδίαση του δικτύου (βάθος, μέγεθος φίλτρου (kernels), κ.λπ.).

3.3 Μοντέλα Attention και Transformers

Οι Transformers εισήχθησαν ως αρχιτεκτονική ακολουθιών με μηχανισμό **αυτο-προσοχής** (self-attention) [6]. Η ιδέα είναι ότι κάθε στοιχείο της εισόδου μπορεί να «συσχετιστεί» **άμεσα** με άλλα στοιχεία, επιτρέποντας μοντελοποίηση μακρινών εξαρτήσεων χωρίς να απαιτείται πολύ μεγάλο βάθος όπως στα προαναφερθέντα CNNs. Το πλεονέκτημα αυτό συνοδεύεται από τετραγωνικό κόστος ως προς το πλήθος tokens, κάτι που γίνεται κρίσιμο σε υψηλής ανάλυσης 2D/3D εισόδους.

3.3.1 Βασικός μηχανισμός self-attention

Για μια ακολουθία n tokens (π.χ. patches εικόνας), το self-attention υπολογίζει:

$$\text{Att}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (3.2)$$

όπου Q, K, V (queries, keys, values) είναι γραμμικοί μετασχηματισμοί των tokens. Η multi-head εκδοχή εφαρμόζει πολλαπλές τέτοιες προσοχές παράλληλα, ώστε το μοντέλο να μαθαίνει διαφορετικούς τύπους συσχετίσεων.

3.3.2 Self-Attention και Εικόνες: προκλήσεις και λύσεις

Ο κλασικός self-attention έχει $O(n^2)$ υπολογιστική και χωρική πολυπλοκότητα ως προς το πλήθος tokens n . Στην όραση, όμως, το n προκύπτει από το πλήθος patches: για 2D εικόνα $n \approx (H \cdot W)/P^2$, ενώ για 3D όγκο $n \approx (H \cdot W)/P^3$, όπου P είναι η ακμή του patch. Ακόμη και με patching, το n παραμένει μεγάλο για πρακτική 3D εκπαίδευση.

Ο Vision Transformer (ViT) [41] διατύπωσε τη 2D όραση ως ακολουθία patch tokens με positional embeddings. Ωστόσο, για ιατρικά δεδομένα (συχνά μικρότερα σύνολα και 3D όγκοι), απαιτούνται πρόσθετες σχεδιαστικές επιλογές ώστε να είναι πρακτική η εκπαίδευση.

3.3.3 Μείωση κόστους: ιεραρχία, τοπικά παράθυρα και προσεγγίσεις γραμμικής προσοχής

Κύριες κατευθύνσεις για να καταστεί ο attention πρακτικός σε μεγάλες εισόδους είναι:

- **Ιεραρχική αναπαράσταση** με υποδειγματοληψίες, ώστε να μειώνεται σταδιακά το πλήθος tokens.
- **Τοπική προσοχή σε παράθυρα** (window attention): ο Swin Transformer υπολογίζει προσοχή σε τοπικά παράθυρα και τα μετατοπίζει (shifted windows) για ανταλλαγή πληροφορίας μεταξύ τους, επιτυγχάνοντας αποδοτική κλιμάκωση [42].
- **Προσεγγίσεις υπο-τετραγωνικής προσοχής**: π. χ. χαμηλόβαθμη προβολή (Linformer) [43] ή στοχαστικές προσεγγίσεις με random features (Performer) [44].

Στο πλαίσιο ιατρικής τμηματοποίησης, συχνά προτιμώνται οι δύο πρώτες στρατηγικές (ιεραρχία/παράθυρα), επειδή διατηρούν καλύτερα τη χωρική δομή και είναι πιο ‘φιλικές’ σε 3D δεδομένα.

3.3.4 Υβριδικά Transformer–U-shape μοντέλα

Υβριδικά μοντέλα όπως τα UNETR [7] και SwinUNETR [8] χρησιμοποιούν Transformer-ενισχυμένους κωδικοποιητές για καλύτερη κατανόηση συμφραζόμενων, διατηρώντας ταυτόχρονα decoder που ανακτά λεπτομέρεια υψηλής ανάλυσης, όπως στο U-Net. Έτσι επιχειρείται συνδυασμός:

- **παγκόσμιας/μακρινής συσχέτισης** (ισχυρό σημείο των Transformers)
- με **ακριδή χωρική ανακατασκευή** (ισχυρό σημείο της U-shaped αποκωδικοποίησης).

3.4 Μοντέλα Χώρου Καταστάσεων (State Space Models) και Mamba

Τα Μοντέλα Χώρου Καταστάσεων (State Space Models - SSMs) αποτελούν μια κλασική κατηγορία δυναμικών συστημάτων που περιγράφουν την εξέλιξη μιας κρυφής κατάστασης $h_t \in \mathbb{R}^N$ μέσω μιας ακολουθίας εισόδων $x_t \in \mathbb{R}^M$. Σε διακριτή μορφή, ένα γραμμικό, χρονικά

αναλλοίωτο (Linear Time-Invariant - LTI) SSM περιγράφεται από:

$$h_t = \bar{A}h_{t-1} + \bar{B}x_t, \quad (3.3)$$

$$y_t = Ch_t + Dx_t, \quad (3.4)$$

όπου \bar{A}, \bar{B}, C, D είναι οι παράμετροι του μοντέλου. Αυτή η αναδρομική μορφή επιτρέπει θεωρητικά ‘άπειρης’ μνήμη, αλλά για μεγάλες ακολουθίες ο υπολογισμός είναι αυστηρά διαδοχικός και, κατά συνέπεια, αργός. Ωστόσο, αξιοποιώντας την LTI ιδιότητα, η εξέλιξη του συστήματος μπορεί να υπολογιστεί ισοδύναμα ως γραμμική συνέλιξη (global convolution), επιτρέποντας τον πλήρη παραλληλισμό [45].

Παρότι τα LTI SSMs είναι υπολογιστικά αποδοτικά (π.χ. μέσω της ισοδυναμίας με γραμμική συνέλιξη), στην απλή γραμμική τους μορφή συχνά υστερούν σε εκφραστικότητα σε σύγκριση με Transformers [9, 45]. Ένας βασικός λόγος είναι ότι οι παράμετροι (π.χ. \bar{A} και \bar{B}) δεν εξαρτώνται από την είσοδο, άρα απουσιάζει εγγενής content-based selection [9]. Αυτό οδήγησε σε δομημένα SSMs (π.χ. S4) και σε επιλεκτικά SSMs όπως το Mamba, όπου κρίσιμες παράμετροι επηρεάζονται από την είσοδο.

3.4.1 Δομημένα Μοντέλα Χώρου Καταστάσεων (Structured SSMs) και Μοντελοποίηση Μακρινών Εξαρτήσεων

Για να καταστούν τα SSMs ανταγωνιστικά σε προβλήματα με πολύ μεγάλες ακολουθίες (π.χ. ήχος, DNA), εισήχθησαν τα **Δομημένα Μοντέλα Χώρου Καταστάσεων (Structured SSMs)**. Μοντέλα όπως το **S4** επιβάλλουν συγκεκριμένη δομή στον πίνακα κατάστασης, επιτρέποντας αποδοτικό υπολογισμό και στις δύο μορφές μέσω ειδικών αλγορίθμων [45]. Το S4 επέδειξε ισχυρή απόδοση σε εργασίες που απαιτούν μοντελοποίηση μακρινών εξαρτήσεων [45, 46].

3.4.2 Mamba: Επιλεκτικά Μοντέλα Χώρου Καταστάσεων και Γραμμική Κλιμάκωση

Παρόλο που τα δομημένα SSMs (όπως το S4) είναι αποτελεσματικά σε συνεχή σήματα, αντιμετωπίζουν δυσκολίες σε διακριτά δεδομένα όπως το κείμενο, όπου η ικανότητα **επιλογής με βάση το περιεχόμενο** (content-based selection) είναι κρίσιμη [9]. Το μοντέλο **Mamba** επιλύει αυτόν τον περιορισμό εισάγοντας εκλεκτικούς χώρους καταστάσεων (selective state spaces): κρίσιμες παράμετροι (π.χ. \bar{B}, C και το βήμα διακριτοποίησης Δ) γίνονται συναρτήσεις της τρέχουσας εισόδου x_t , επιτρέποντας στο μοντέλο να ‘αποφασίζει’ δυναμικά ποια πληροφορία θα διατηρήσει.

Η αλλαγή αυτή δυσκολεύει τη χρήση καθαρής συνελκτικής μορφής, οπότε το Mamba βασίζεται σε **υλοποίηση βελτιστοποιημένη για GPU** (hardware-aware scan), ώστε να διατηρεί **γραμμική πολυπλοκότητα** $O(L)$ ως προς το μήκος L της ακολουθίας, με υψηλή πρακτική αποδοτικότητα [9].

3.4.3 Εφαρμογή SSMS/Mamba σε 3D Τμηματοποίηση

Για την εφαρμογή των SSMS σε ογκομετρικά δεδομένα, απαιτείται η σειριοποίηση του όγκου σε ακολουθία (serialization). Μια τυπική μεθοδολογία περιλαμβάνει:

1. Διαχωρισμό του 3D όγκου σε patches και προβολή σε tokens.
2. Ιεραρχική αρχιτεκτονική τύπου U-shaped για multi-scaling processing.
3. Ενσωμάτωση Mamba blocks που αντικαθιστούν τα στρώματα προσοχής ή μέρος των συνελκτικών blocks.

Με αυτόν τον τρόπο, το μοντέλο μπορεί να συλλάβει **μακρινές χωρικές εξαρτήσεις** σε ολόκληρο τον όγκο με σημαντικά χαμηλότερο υπολογιστικό κόστος σε σχέση με πλήρη self-attention. Πρόσφατες προσεγγίσεις όπως το SegMamba [10] δείχνουν ότι η ιδέα αυτή μπορεί να δώσει ανταγωνιστική ακρίβεια σε 3D τμηματοποίηση.

3.4.4 Συγκριτική Επισκόπηση

Συνοψίζοντας τη θεωρητική προοπτική για την τμηματοποίηση πλακούντα:

- **CNNs / U-Net:** Αποδοτικά για τοπικό σήμα, αλλά η ‘παγκόσμια’ πληροφορία εισάγεται έμμεσα (μέσω βάθους).
- **Transformers:** Παρέχουν άμεση καθολική συσχέτιση (global context), αλλά το τετραγωνικό κόστος $O(L^2)$ είναι συχνά απαγορευτικό για υψηλής ανάλυσης 3D δεδομένα.
- **SSMs / Mamba:** Στοχεύουν σε **γραμμική κλιμάκωση** $O(n)$ με ικανότητα μοντελοποίησης μακρινών εξαρτήσεων, αποτελώντας υποσχόμενη μέση λύση.

3.5 Βελτιστοποίηση και πρακτικές εκπαίδευσης

Η εκπαίδευση βαθιών δικτύων πραγματοποιείται συνήθως με στοχαστική κλίση κατάβασης και παραλλαγές της. Ο AdamW αποτελεί διαδεδομένο βελτιστοποιητή, ο οποίος αποσυνδέει το weight decay από την ενημέρωση παραμέτρων, προσφέροντας συχνά καλύτερη γενίκευση [47].

Στην 3D τμηματοποίηση ακολουθούνται κατά κανόνα οι εξής πρακτικές:

- **Μικρό batch size** λόγω περιορισμών στη μνήμη της GPU.
- **Εκπαίδευση με patches** και ισορροπία θετικών/αρνητικών δειγμάτων.
- **Μεταβαλλόμενος ρυθμός μάθησης** (learning rate schedules) για επίτευξη βέλτιστης σύγκλισης (π.χ. CyclicLR, Cosine Annealing [48]).
- **Κανονικοποίηση** (π.χ. GroupNorm ή InstanceNorm) όταν το batch size είναι πολύ μικρό.

Στην παρούσα εργασία, οι παραπάνω επιλογές εφαρμόζονται ενιαία στα πειράματα, με στόχο τη διασφάλιση μιας **δίκαιης σύγκρισης** μεταξύ διαφορετικών αρχιτεκτονικών. Με τον τρόπο αυτό, απομονώνεται η επίδραση της σχεδίασης του μοντέλου στην ακρίβεια τμηματοποίησης πλακών σε εικόνες MRI, ελαχιστοποιώντας την επιρροή των υπερπαραμέτρων εκπαίδευσης [11].

Κεφάλαιο 4

Αρχιτεκτονικές Τμηματοποίησης που Χρησιμοποιήθηκαν

Στο κεφάλαιο αυτό παρουσιάζονται οι αρχιτεκτονικές που χρησιμοποιήθηκαν στα πειράματα της παρούσας εργασίας. Η ανάλυση εστιάζει στον τρόπο με τον οποίο κάθε μοντέλο συλλέγει context (τοπικό ή μακρινής εμβέλειας), καθώς και στους συμβιβασμούς ακρίβειας, μνήμης και υπολογιστικού κόστους στην 3D ιατρική τμηματοποίηση.

4.1 Το πλαίσιο MONAI

Το MONAI (Medical Open Network for AI) είναι ένα ανοικτού κώδικα, PyTorch-βασεδ πλαίσιο που στοχεύει στη διευκόλυνση ανάπτυξης και αξιολόγησης μοντέλων Βαθιάς Μάθησης για εφαρμογές υγείας, με έμφαση στην ιατρική απεικόνιση [11]. Παρέχει:

- **Μετασχηματισμούς** (transforms) για 3D δεδομένα (φόρτωση, resampling, κανονικοποίηση, augmentation).
- **Έτοιμες αρχιτεκτονικές** τμηματοποίησης και building blocks (συνελικτικά/υπολειμματικά βλοκς, κανονικοποιήσεις, upsampling).
- **Απώλειες και μετρικές** (π.χ. Dice-based losses και Dice/IoU μετρικές) και τυποποιημένες ροές εκπαίδευσης.
- **Μηχανισμούς inference** όπως sliding-window inference για μεγάλους 3D όγκους.

Η χρήση του MONAI επιτρέπει πιο **αναπαραγώγιμο** και **συγκρίσιμο** πειραματικό πρωτόκολλο, καθώς πολλές επιλογές υλοποίησης είναι κοινές και ελεγχόμενες [11]. Για περαιτέρω τεχνικές λεπτομέρειες παραπέμπουμε στην επίσημη τεκμηρίωση και στο αποθετήριο του έργου [49, 50].

4.1.1 Υλοποίηση μοντέλων στην παρούσα εργασία

Στην παρούσα εργασία, όλες οι αρχιτεκτονικές UNet, DynUNet, SegResNet, AttentionUnet, UNETR και SwinUNETR χρησιμοποιούνται μέσω των αντίστοιχων υλοποιήσεων του MONAI [11]. Εξαιρέση αποτελεί το SegMamba, το οποίο **δεν διατίθεται στο MONAI** και ενσωματώνεται μέσω της **επίσημης υλοποίησης των συγγραφέων** [10, 51]. Για να διατηρηθεί

δίκαιη σύγκριση, το SegMamba εκπαιδεύεται και αξιολογείται με το ίδιο πρωτόκολλο προεπεξεργασίας, δειγματοληψίας patches, απώλειας, μετρικών και sliding-window inference που εφαρμόζεται και στα MONAI-μοντέλα.

4.2 Οικογένειες μοντέλων που συγκρίνονται

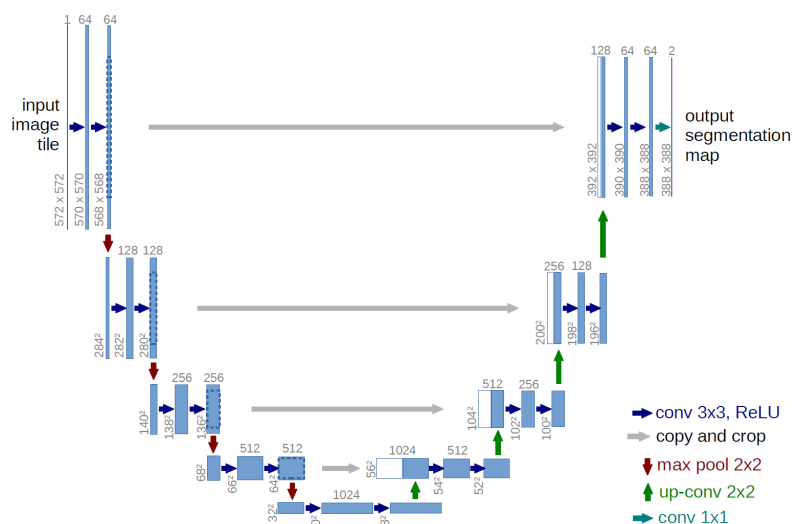
Η αρχιτεκτονικές ομαδοποιούνται ως εξής:

- **CNN-based:** UNet, DynUNet, SegResNet, AttentionUnet.
- **Transformer-ενισχυμένα:** UNETR, SwinUNETR.
- **SSM/Mamba-based:** SegMamba (εκτός MONAI, μέσω επίσημου κώδικα).

4.3 UNet και 3D U-Net

Το U-Net [5] αποτελεί σημείο αναφοράς στην ιατρική τμηματοποίηση. Πρόκειται για συμμετρική αρχιτεκτονική 4.1 encoder-decoder με skip connections:

- Ο **κωδικοποιητής** (encoder) μειώνει την ανάλυση (downsampling), αυξάνοντας τα κανάλια, ώστε να κωδικοποιεί υψηλού επιπέδου χαρακτηριστικά.
- Ο **αποκωδικοποιητής** (decoder) ανακτά την ανάλυση (upsampling) και συνδυάζει πληροφορία υψηλής ανάλυσης από τον encoder, ώστε να βελτιώνει την ακρίβεια εντοπισμού ορίων.



Σχήμα 4.1: Δομή αρχιτεκτονικής U-net

Για ογκομετρικά δεδομένα, η λογική επεκτείνεται σε 3D U-Net με 3D συνελιξείς [38]. Τα skip connections είναι κρίσιμα για ακριβή localization, καθώς μετριάζουν την απώλεια λεπτομέρειας στα στάδια υποδειγματοληψίας.

Σχόλιο. Το UNet τείνει να αποδίδει πολύ καλά σε τοπικά μορφολογικά μοτίβα και οριακές μεταβολές. Ο κύριος περιορισμός είναι ότι το global context εισάγεται έμμεσα μέσω βάθους και multi-scaling συμπίεσης.


4.4 DynUNet

Το DynUNet (στη MONAI υλοποίηση) είναι παραλλαγή 3D UNet που επιτρέπει **δυναμική** προσαρμογή της τοπολογίας (στάδια, strides, μεγέθη μυρήνων) με βάση τις διαστάσεις/ανάλυση εισόδου και το patch size. Η φιλοσοφία συνδέεται με το nnU-Net, όπου έδειξε ότι συστηματικές επιλογές προεπεξεργασίας και ‘εύλογες’ αρχιτεκτονικές αποφάσεις μπορούν να δώσουν ισχυρά αποτελέσματα σε πολλά datasets [52].

Κεντρική ιδέα. Η προσαρμογή επιδιώκει επαρκές receptive field με ελεγχόμενο κόστος, ώστε να μην χάνεται υπερβολικά χωρική πληροφορία σε 3D δεδομένα. Συχνά υποστηρίζεται και deep supervision, που μπορεί να βοηθήσει στη σύγκλιση σε ρυθμίσεις μικρού batch size [52].

4.5 SegResNet: υπολειμματικό encoder-decoder

Το SegResNet χρησιμοποιεί υπολειμματικά blocks τύπου ResNet [1] μέσα σε encoder-decoder σχήμα. Μία επιδραστική μορφή αυτού του συλ για 3D MRI τμηματοποίηση είναι η προσέγγιση του Myronenko [12], όπου η υπολειμματική δομή συνδυάζεται και με autoencoder regularization.



Σχήμα 4.2: Μηχανισμός residual connection στην αρχιτεκτονική ResNet [1]

Γιατί υπολείμματα. Οι υπολειμματικές συνδέσεις (4.1) διευκολύνουν τη ροή κλίσεων και επιτρέπουν εκπαίδευση βαθύτερων δικτύων με σταθερότερη σύγκλιση [1]. Αυτό είναι χρήσιμο όταν απαιτείται μεγαλύτερο βάθος για ενσωμάτωση συμφραζομένων σε 3D όγκους.

4.6 AttentionUnet: προσοχή στις skip connections

Η Attention U-Net εισάγει attention gates στις skip connections, ώστε το δίκτυο να ενισχύει περιοχές σχετικές με το ROI και να καταστέλλει άσχετο υπόβαθρο [13]. Το gate συνδυάζει πληροφορία από ρηχότερα επίπεδα (λεπτομέρεια) και βαθύτερα επίπεδα (συμφραζόμενο), υπολογίζοντας βάρη εστίασης.

Πότε βοηθά. Η προσοχή είναι ιδιαίτερα χρήσιμη όταν το ROI είναι μικρό, υπάρχει ισχυρή ανισορροπία κλάσεων ή όταν δομές έχουν παρόμοια ένταση με το υπόβαθρο.

4.7 UNETR: ViT encoder με U-shaped decoder

Το UNETR [7] αποτελεί υβριδικό σχήμα, όπου ο encoder βασίζεται σε Transformer (ViT-like) και ο decoder διατηρεί τη λογική ανακατασκευής τύπου U-Net. Η είσοδος χωρίζεται σε μη επικαλυπτόμενα **3D patches** που προβάλλονται σε tokens, ενώ το self-attention επιτρέπει άμεση μοντελοποίηση μακρινών συσχετίσεων.

Σχόλιο κόστους. Το πλεονέκτημα του global context συνοδεύεται από αυξημένο κόστος μνήμης/χρόνου, το οποίο εξαρτάται έντονα από το patch grid. Για αυτό, η επιλογή patch size και ο τρόπος ινference (π.χ. sliding-window) είναι κρίσιμα πρακτικά σημεία [7].

4.8 SwinUNETR: ιεραρχικός Swin encoder

Το SwinUNETR βασίζεται σε Swin Transformer encoder με ιεραρχία και window-based attention [8, 42]. Αντί για πλήρη attention σε όλα τα tokens, η προσοχή υπολογίζεται σε τοπικά παράθυρα, τα οποία μετατοπίζονται (shifted windows) ώστε να επιτυγχάνεται ανταλλαγή πληροφορίας μεταξύ γειτονικών παραθύρων.

Γιατί ταιριάζει σε 3D. Η ιεραρχία μειώνει προοδευτικά το πλήθος tokens (patch-merging), βελτιώνοντας την κλιμάκωση. Παράλληλα, οι skip connections προς έναν U-shaped decoder διατηρούν την χωρική ακρίβεια.

4.9 SegMamba: Mamba/SSM blocks σε U-shape σχεδίαση

Το SegMamba προτείνει μια 3D αρχιτεκτονική τμηματοποίησης που ενσωματώνει Mamba-βασισμένα SSM βλοκς για μοντελοποίηση μακρινών εξαρτήσεων με ευνοϊκή κλιμάκωση σε σχέση με πλήρες self-attention [10]. Ο μηχανισμός Mamba εισάγει selective state spaces, επιτρέποντας content-dependent παραμετροποίηση που λειτουργεί ως εναλλακτική της attention σε μεγάλες ακολουθίες [9].

Σημείωση υλοποίησης. Σε αντίθεση με τα υπόλοιπα μοντέλα που προέρχονται από MONAI, η αρχιτεκτονική SegMamba υλοποιείται στην παρούσα εργασία μέσω του **επίσημου αποθετηρίου** των συγγραφέων [51]. Η ενσωμάτωση γίνεται με τρόπο που να επιτρέπει κοινό πειραματικό πρωτόκολλο (προεπεξεργασία, patch sampling, loss, metrics και inference), ώστε η σύγκριση να παραμένει συνεπής.

Αναμενόμενη συμπεριφορά. Η σχεδίαση στοχεύει να συνδυάσει:

- συλλογή **μακρινής** εμβέλειας πληροφοριών σε πολλαπλές κλίμακες,
- U-shaped αποκωδικοποίηση για διατήρηση χωρικής ακρίβειας,

- βελτιωμένη διαχείριση πόρων σε 3D δεδομένα, σε σύγκριση με Transformer encoders αντίστοιχης ανάλυσης.

4.10 Συζήτηση: αναμενόμενοι συμβιβασμοί

Συνοψίζοντας, οι οικογένειες μοντέλων διαφέρουν ως προς το **πώς** συλλέγουν συμφραζόμενο:

- **CNN-based:** ισχυρά σε όρια/υφές και αποδοτικά, αλλά το global context εισάγεται έμμεσα.
- **Transformer-based:** ισχυρό global context, αλλά αυξημένες απαιτήσεις μνήμης/χρόνου.
- **SSM/Mamba-based:** στόχος η μακρινής εμβέλειας μοντελοποίηση με καλύτερη κλιμάκωση, κάτι ιδιαίτερα ελκυστικό σε 3D τμηματοποίηση.

Στο πειραματικό μέρος παρουσιάζεται το κοινό πρωτόκολλο εκπαίδευσης/αξιολόγησης που επιτρέπει να αποτιμηθούν εμπειρικά οι παραπάνω συμβιβασμοί για την τμηματοποίηση πλακών σε MRI.

Μέρος **III**

Πρακτικό Μέρος

Κεφάλαιο 5

Πειραματική Αξιολόγηση και Αποτελέσματα

Στο κεφάλαιο αυτό παρουσιάζεται η πειραματική διαδικασία που ακολουθήθηκε για την εκπαίδευση και τη συγκριτική αξιολόγηση διαφορετικών αρχιτεκτονικών τμηματοποίησης σε 3D MRI, καθώς και τα αντίστοιχα αποτελέσματα.

Η επιλογή των μοντέλων προέκυψε μέσα από συστηματική μελέτη της βιβλιογραφίας: αρχικά εξετάστηκαν τα θεμελιώδη U-shaped δίκτυα (U-Net) [5] και στη συνέχεια παραλλαγές/επεκτάσεις όπως το Attention U-Net [13] και σύγχρονες U-Net μορφές όπως το DynUNet [52]. Τέλος, αξιολογήθηκαν νεότερες προσεγγίσεις που μοντελοποιούν μακρινές εξαρτήσεις, όπως τα Transformer-based μοντέλα (UNETR [7], SwinUNETR [8]) και State Space-based μοντέλα (SegMamba [10], βασισμένο στο Mamba [9]).

Κεντρικός στόχος είναι η **δίκαιη και αναπαραγώγιμη σύγκριση** των αρχιτεκτονικών. Για τον λόγο αυτό υλοποιήθηκε ένα **ενιαίο πειραματικό πλαίσιο** όπου όλες οι αρχιτεκτονικές εκπαιδεύονται με κοινή ροή (pipeline) προεπεξεργασίας, δειγματοληψίας patches, εκπαίδευσης, αξιολόγησης και καταγραφής μετρικών. Στην πράξη, κάθε αρχιτεκτονική αντιστοιχεί σε ξεχωριστό notebook, όμως η δομή του κώδικα παραμένει σταθερή, με κύρια διαφοροποίηση την αρχικοποίηση του μοντέλου και ελάχιστες αναγκαίες ρυθμίσεις συμβατότητας.

5.1 Στόχοι αξιολόγησης και αρχές σύγκρισης

Στόχος της πειραματικής αξιολόγησης είναι να αποτυπωθεί με σαφήνεια η σχετική συμπεριφορά διαφορετικών οικογενειών αρχιτεκτονικών σε τμηματοποίηση πλακούντα σε 3D MRI. Η σύγκριση σχεδιάστηκε ώστε να είναι δίκαιη, με κοινό τρόπο αναφοράς αποτελεσμάτων και συνεπείς επιλογές αξιολόγησης, έτσι ώστε οι παρατηρούμενες διαφορές να αποδίδονται κατά το δυνατόν στην αρχιτεκτονική.

Η αναφορά βασίζεται κυρίως σε Dice και IoU, μετρικές που είναι κατάλληλες για προβλήματα έντονης ανισορροπίας κλάσεων, ενώ η ερμηνεία δεν στηρίζεται μόνο στη μέση τιμή αλλά συμπληρώνεται από ποιοτική επιθεώρηση και σχολιασμό τυπικών αποτυχιών ανά περίπτωση (βλ. Κεφάλαιο 6).

5.2 Υλοποίηση και λογισμικό

Η υλοποίηση πραγματοποιήθηκε στο PyTorch, με χρήση του MONAI [11], το οποίο παρέχει έτοιμες αρχιτεκτονικές, μετασχηματισμούς (transforms), συναρτήσεις απώλειας, και εργαλεία αξιολόγησης κατάλληλα για 3D ιατρική τμηματοποίηση.

Όλες οι αρχιτεκτονικές (εκτός του SegMamba, που ενσωματώθηκε ως εξωτερική υλοποίηση) χρησιμοποιούν κοινές συνιστώσες του MONAI για :

- (α) ανάγνωση NIfTI δεδομένων,
- (β) προεπεξεργασία/επαύξηση,
- (γ) sliding-window inference,
- (δ) υπολογισμό μετρικών.

5.3 Σύνολο δεδομένων και διαχωρισμός

Το σύνολο δεδομένων περιλαμβάνει $N = 137$ περιστατικά, με ένα ζεύγος αρχείων .nii.gz ανά περίπτωση: έναν ογκομετρικό όγκο MRI και την αντίστοιχη δυαδική μάσκα τμηματοποίησης πλακούντα. Ως βασική μονάδα εκπαίδευσης και αξιολόγησης ορίζεται το case (δηλαδή ολόκληρος ο 3D όγκος), ώστε ο διαχωρισμός να γίνεται σε επίπεδο ασθενή/περίπτωσης και να αποφεύγεται διαρροή πληροφορίας.

Ο διαχωρισμός σε σύνολα εκπαίδευσης και επικύρωσης πραγματοποιείται με σταθερό seed (121) για λόγους αναπαραγωγιμότητας. Στα πειράματα της παρούσας εργασίας χρησιμοποιήθηκε διαχωρισμός 80/20, που αντιστοιχεί περίπου σε 109 περιστατικά εκπαίδευσης και 28 επικύρωσης.

5.4 Αρχιτεκτονικές και πειραματικά σενάρια

Αξιολογήθηκαν οι παρακάτω αρχιτεκτονικές:

- U-Net [5]
- Attention U-Net [13]
- DynUNet [52]
- UNETR [7]
- SwinUNETR [8]
- SegResNet [12]
- SegMamba [10]

Οικογένειες μοντέλων. Οι αρχιτεκτονικές που αξιολογούνται καλύπτουν κλασικές CNN προσεγγίσεις (U-Net και παραλλαγές), νεότερες Transformer-βασισμένες δομές (UNETR, SwinUNETR) και αποδοτικές εναλλακτικές για μοντελοποίηση μακρινών εξαρτήσεων (state space-βασεδ, SegMamba). Με αυτόν τον τρόπο εξετάζεται τόσο η επίδραση ισχυρού τοπικού inductive bias όσο και η συμβολή μηχανισμών παγκόσμιου context.

5.4.1 Αρχιτεκτονικές υπερπαράμετροι ανά μοντέλο

Παρότι το πειραματικό πρωτόκολλο (προεπεξεργασία, δειγματοληψία, optimizer, κ.λπ.) διατηρήθηκε κοινό, κάθε αρχιτεκτονική απαιτεί ορισμένες *ειδικές* υπερπαραμέτρους που καθορίζουν κυρίως τη χωρητικότητα (capacity) και τη δομή του encoder/decoder. Το dropout ορίστηκε 0.0 σε κάθε περίπτωση. Συνοπτικά, χρησιμοποιήθηκαν:

- **U-Net:** channels (16, 32, 64, 128, 256), strides (2, 2, 2, 2), num_res_units = 2.
- **Attention U-Net:** channels (16, 32, 64, 128, 256), strides (2, 2, 2, 2), kernel_size = 3, up_kernel_size = 3.
- **DynUNET:** kernel_size = [3, 3, 3, 3], strides = [1, 2, 2, 2], upsample_kernel_size = [2, 2, 2], deep_supervision = False.
- **UNETR:** img_size (96, 96, 64), feature_size = 32, hidden_size = 768, mlp_dim = 3072, num_heads = 24, proj_type="conv", res_block=True.
- **SwinUNETR:** img_size (96, 96, 64), feature_size = 60, patch_size = 2, window_size = 5, depths (2, 2, 2, 2), use_checkpoint=True.
- **SegResNet:** βασικές παράμετροι όπως προαρμογή πλάτους επιπέδων (init_filters) και η κατανομή blocks στο down/up path. Εκτελέστηκαν δύο ρυθμίσεις:
 - SegResNet 1: init_filters= 64, blocks_down= [1, 2, 2, 4], blocks_up= [1, 1, 1].
 - SegResNet 2: init_filters= 32, blocks_down= [1, 2, 2, 4], blocks_up= [1, 1, 1].
- **SegMamba:** βασικές παράμετροι το 'πλάτος' χαρακτηριστικών (feat_size) και το βάθος (depths). Εκτελέστηκαν δύο ρυθμίσεις:
 - SegMamba 1: feat_size= 32, depths= [2, 2, 2, 2, 2].
 - SegMamba 2: feat_size= 32, depths= [2, 2, 2, 2].

Οι παραπάνω ρυθμίσεις αφορούν αποκλειστικά τη **χωρητικότητα της αρχιτεκτονικής** και όχι το εκπαιδευτικό πρωτόκολλο, το οποίο παρέμεινε κοινό για όλα τα μοντέλα.

Για κάθε αρχιτεκτονική εκτελέστηκε μία βασική εκπαίδευση (baseline run) με το κοινό pipeline. Επιπλέον πραγματοποιήθηκαν ενισχυμένα πειράματα (stronger runs) για επιλεγμένα μοντέλα (π. χ. SegResNet και SwinUNETR), με στόχο να διερευνηθεί η επίδραση ρυθμίσεων που αυξάνουν την ικανότητα του δικτύου ή/και βελτιώνουν τη σταθερότητα σύγκλισης (π. χ. μεταβολές σε feature size, window size, βάθος, κ. ά.). Οι αποκλίσεις αυτές από τη βασική ρύθμιση καταγράφονται ρητά στις αντίστοιχες υποενότητες αποτελεσμάτων.

5.5 Υπολογιστικό περιβάλλον και εκτέλεση πειραμάτων

Τα πειράματα υλοποιήθηκαν σε Python/PyTorch με τη βιβλιοθήκη MONAI [11]. Η εκπαίδευση εκτελέστηκε σε περιβάλλον cloud μέσω της πλατφόρμας Kaggle Notebooks (με επαλήθευση μέσω τηλεφώνου), αξιοποιώντας GPU επιτάχυνση (π.χ. NVIDIA T4 σε διαθέσιμη διαμόρφωση) εντός του εβδομαδιαίου ορίου χρήσης που παρέχεται από την πλατφόρμα.¹

Οι εκτελέσεις πραγματοποιήθηκαν ως *non-interactive runs* (batch-style εκπαίδευση με καταγραφή logs/μετρικών), ώστε να διατηρείται σταθερή η διαδικασία μεταξύ μοντέλων και να αποφεύγονται χειροκίνητες παρεμβάσεις. Για αναπαραγωγικότητα χρησιμοποιήθηκαν σταθερά seeds σε Python, NumPy και PyTorch, καθώς και κοινή δομή κώδικα για όλα τα μοντέλα (με διαφοροποίηση κυρίως στην αρχικοποίηση της αρχιτεκτονικής).

5.6 Οργάνωση δεδομένων και ροή φόρτωσης

Κάθε περιστατικό περιλαμβάνει έναν 3D MRI όγκο και την αντίστοιχη δυαδική μάσκα πλακώντας σε μορφή NIfTI (.nii.gz). Τα δεδομένα μετατρέπονται σε λίστα από dictionaries (paths για image και label), η οποία τροφοδοτείται σε Dataset του MONAI.

Για επιτάχυνση, το αιτιοκρατικό τμήμα της προεπεξεργασίας προϋπολογίζεται μια φορά και αποθηκεύεται σε disk cache μέσω **PersistentDataset**. Αντιθέτως, οι στοχαστικοί μετασχηματισμοί (Random Augmentations, εφαρμόζονται μόνο στο training set) εκτελούνται κάθε εποχή κατά τη φόρτωση των δεδομένων μέσω DataLoader. Αυτό συμβαίνει ώστε να έχουμε διαφορετικές παραλλαγές των ίδιων δειγμάτων χωρίς επαναλαμβανόμενο κόστος σταθερής προεπεξεργασίας.

5.7 Ανάλυση στοίβας προεπεξεργασίας

Η προεπεξεργασία σχεδιάστηκε με γνώμονα δύο βασικά χαρακτηριστικά του προβλήματος: (α) την υψηλή ανισορροπία background/foreground (ο πλακούντας καταλαμβάνει μικρό μέρος του όγκου) και (β) την ανάγκη γεωμετρικής συνέπειας μεταξύ περιστατικών. Οι μετασχηματισμοί επιλέχθηκαν από το MONAI [53].

5.7.1 Γεωμετρική εναρμόνιση και σταθεροποίηση εισόδου

Το πρώτο στάδιο εξασφαλίζει ότι όλα τα δεδομένα «βλέπονται» από το μοντέλο σε κοινό γεωμετρικό πλαίσιο:

- **Φόρτωση και τυποποίηση:** ανάγνωση NIfTI, μεταφορά σε tensor και εξασφάλιση σωστού καναλιού (channel-first), ώστε οι επόμενοι μετασχηματισμοί να εφαρμόζονται ομοιόμορφα.
- **Επαναπροσανατολισμός (Orientation):** μετατροπή σε κοινό σύστημα αξόνων (RAS), ώστε να αποφεύγονται ασυνέπειες σε λεφτ/ριγίτ, αντεριωρ/ποστεριωρ κ.λπ.

¹Οι ακριβείς διαθέσιμοι πόροι και τα όρια χρήσης μπορεί να μεταβάλλονται με τον χρόνο και εξαρτώνται από την πολιτική της πλατφόρμας.

- **Αναδειγματοληψία (Spacing):** μετασχηματισμός σε κοινό voxel spacing (π.χ. (2, 2, 2) mm), ώστε η μάθηση να μην επηρεάζεται από διαφορετικές φυσικές κλίμακες και ανομοιογενές resolution μεταξύ εξετάσεων.

5.7.2 Κανονικοποίηση εντάσεων

Οι MRI εντάσεις δεν είναι άμεσα συγκρίσιμες όπως σε CT, συνεπώς εφαρμόζεται κανονικοποίηση με percentiles (π.χ. 2–99.9) και χαρτογράφηση στο [0, 1]. Η πρακτική αυτή (α) περιορίζει την επίδραση ουτλιερσ/θορύβου και (β) διευκολύνει τη σταθερότητα του οπτιμιζατιον.

5.7.3 Περιορισμός πεδίου (POI) με foreground cropping

Δεδομένης της μεγάλης έκτασης background, εφαρμόστηκε CropForegroundd με source_key=label και μικρό περιθώριο (margin) ώστε να περιορίζεται το FOV γύρω από την περιοχή ενδιαφέροντος. Με τον τρόπο αυτό μειώνεται δραστικά η σπατάλη υπολογισμού σε κενές περιοχές, αυξάνοντας την πιθανότητα τα patches να περιέχουν χρήσιμη πληροφορία.

5.7.4 Σταθεροποίηση διαστάσεων για συμβατότητα μοντέλων

Τέλος, εφαρμόζεται:

- **Padding σε σταθερό roi_size** (π.χ. (96, 96, 64)), για ομοιόμορφη εκπαίδευση με patch-based στρατηγική.
- **Divisible padding** ώστε οι τελικές διαστάσεις να είναι πολλαπλάσια συγκεκριμένων παραγόντων (π.χ. (32, 32, 16)), κάτι που διευκολύνει αρχιτεκτονικές με downsampling/patch merging.

5.8 Δειγματοληψία patches και επαύξηση δεδομένων

Λόγω του μεγέθους των 3D όγκων και περιορισμών μνήμης, η εκπαίδευση πραγματοποιείται σε patches σταθερού μεγέθους (roi_size). Για την αντιμετώπιση της έντονης ανισορροπίας background/foreground χρησιμοποιήθηκε RandCropByPosNegLabeld, ώστε να ελέγχεται η πιθανότητα επιλογής patches που περιέχουν foreground.

Επιπλέον εφαρμόστηκε μεταβολή στην αναλογία pos/neg κατά τη διάρκεια της εκπαίδευσης, με στόχο αρχικά να σταθεροποιηθεί η μάθηση πάνω στο foreground και στη συνέχεια να μειωθούν τα false positives μέσω σταδιακής εισαγωγής αρνητικών δειγμάτων. Για τα πρώτα 40 epochs είχαμε αποκλειστικά foreground δεδομένα, έπειτα για 30 epochs υπήρχε αναλογία 3/1 positive to negative, και για τις υπόλοιπες εποχές ισάξια αναλογία θετικών προς αρνητικών δειγμάτων.

Για βελτίωση της γενίκευσης, εφαρμόστηκαν στοχαστικές επαυξήσεις (random flips, ήπιες περιστροφές/αφινικοί μετασχηματισμοί, Gaussian θόρυβος/εξομάλυνση), οι οποίες προσομοιώνουν ρεαλιστική μεταβλητότητα χωρίς να αλλοιώνουν τη σημασιολογία της μάσκας.

5.9 Συνάρτηση κόστους και βελτιστοποίηση

5.9.1 Κριτήριο εκπαίδευσης

Ως βασικό κριτήριο χρησιμοποιήθηκε η DiceCELoss (Dice + Cross-Entropy), με sigmoid έξοδο και `include_background=False`. Ο συνδυασμός Dice και CE είναι πρακτικός σε έντονα ανισόρροπες τμηματοποιήσεις, καθώς ο Dice στοχεύει άμεσα στην επικάλυψη, ενώ το CE συνεισφέρει σταθερότητα και καλύτερη συμπεριφορά γραδιεντς σε πρώιμα στάδια σύγκλισης.

5.10 Επικύρωση και διαδικασία inference

5.10.1 Sliding Window Inference (SWI)

Η επικύρωση σε πλήρεις 3D όγκους είναι συχνά αδύνατη σε μνήμη, ειδικά για βαριά μοντέλα. Για τον λόγο αυτό εφαρμόστηκε sliding-window inference με επικάλυψη (overlap) και gaussian blending, ώστε να συντίθεται τελική πρόβλεψη σε όλο τον όγκο χωρίς να θυσιάζεται η ποιότητα στα όρια των patches.

5.10.2 EMA (Exponential Moving Average)

Παράλληλα, χρησιμοποιήθηκε EMA, δηλαδή εκθετικός κινητός μέσος των παραμέτρων του μοντέλου. Η αξιολόγηση με EMA τείνει να είναι πιο σταθερή από το στιγμιαίο checkpoint, ειδικά όταν ο ρυθμός μάθησης κυμαίνεται σε εύρος.

5.11 Βελτιστοποίηση και Scheduler

5.11.1 Optimizer

Για όλα τα μοντέλα χρησιμοποιήθηκε ο AdamW [47], καθώς αποτελεί μια σταθερή και ευρέως χρησιμοποιούμενη επιλογή για deep δίκτυα, ειδικά σε 3D ιατρική τμηματοποίηση. Σε σχέση με τον κλασικό Adam, ο AdamW εφαρμόζει αποσυνδεδεμένη (decoupled) κανονικοποίηση weight decay, κάτι που συνήθως οδηγεί σε πιο συνεπή ρύθμιση της γενίκευσης χωρίς να επηρεάζονται ανεπιθύμητα οι ενημερώσεις των παραμέτρων. Οι βασικές υπερπαραμέτροι (όπως το learning rate και το weight decay) διατηρήθηκαν όσο το δυνατόν κοινές μεταξύ αρχιτεκτονικών, ώστε οι διαφορές στην απόδοση να αποδίδονται κατά κύριο λόγο στη δομή του μοντέλου και όχι στη διαδικασία βελτιστοποίησης.

5.11.2 Scheduler

Ο ρυθμός μάθησης (learning rate) μεταβαλλόταν δυναμικά κατά τη διάρκεια της εκπαίδευσης με CyclicLR [54] (σχήμα triangular2). Στο συγκεκριμένο σχήμα ο ρυθμός μάθησης αυξάνεται γραμμικά από β ως α και στη συνέχεια μειώνεται πάλι, ενώ σε κάθε επόμενο κύκλο το εύρος ταλάντωσης μειώνεται, οδηγώντας σε πιο «ήπια» εξερεύνηση στα όψιμα στάδια. Η επιλογή κυκλικού χρονοπρογραμματισμού εξυπηρετεί δύο στόχους: (i)

μειώνει την ευαισθησία σε μία μοναδική επιλογή learning rate, και (ii) λειτουργεί ως μηχανισμός εξερεύνησης του χώρου λύσεων, κάτι που συχνά βοηθά σε πιο σταθερή σύγκλιση όταν συνδυάζεται με έντονες στοχαστικές διεργασίες (όπως data augmentation και patch sampling). Σημειώνεται ότι στα διαγράμματα ιστορικού εκπαίδευσης αποτυπώνεται ο κυκλικός χαρακτήρας του LR, καθώς και η χρονική στιγμή στην οποία επιτυγχάνεται η καλύτερη επίδοση στο validation (π.χ. μέγιστο Dice), που χρησιμοποιείται και ως κριτήριο επιλογής checkpoint.

Κεφάλαιο 6

Αποτελέσματα Πειραματικής Αξιολόγησης

Στο κεφάλαιο αυτό παρουσιάζονται τα αποτελέσματα της συγκριτικής αξιολόγησης των αρχιτεκτονικών τμηματοποίησης που περιγράφηκαν στο Κεφάλαιο 5. Όλα τα μοντέλα εκπαιδεύτηκαν και αξιολογήθηκαν με ενιαίο πειραματικό πρωτόκολλο (προεπεξεργασία, δειγματοληψία, βελτιστοποίηση, επικύρωση), ώστε οι διαφορές στο τέλος να αποδίδονται όσο το δυνατόν περισσότερο στην αρχιτεκτονική και όχι σε ασυνεπείς ρυθμίσεις ή διαδικασίες.

Πρώτα, παρατίθενται τα ποσοτικά αποτελέσματα στα δεδομένα αξιολόγησης μέσω μετρικών επικάλυψης (Dice, IoU) και της τιμής της απώλειας επικύρωσης (validation loss). Δεύτερον, συμπληρώνονται με ποιοτική αξιολόγηση μέσω οπτικών προβλέψεων έναντι ground truth, ως αξιολόγηση των αριθμητικών δεικτών για το εάν αντιπροσωπεύουν την πραγματικότητα.

Στις επόμενες ενότητες παρουσιάζεται αρχικά η συνοπτική κατάταξη των μοντέλων με βάση τη μέση επίδοση, και στη συνέχεια αναλύονται πιο λεπτομερώς οι τάσεις ανά αρχιτεκτονική, με αναφορές τόσο στις καμπύλες εκπαίδευσης/επικύρωσης όσο και στα οπτικά αποτελέσματα.

6.1 Παρουσίαση αποτελεσμάτων

Τα αποτελέσματα παρουσιάζονται σε δύο επίπεδα :

- **Ποσοτικά:** μετρικές Dice/IoU και απώλειες (train/val loss), με σύγκριση μεταξύ μοντέλων.
- **Ποιοτικά:** ενδεικτικές οπτικοποιήσεις προβλέψεων/σφαλμάτων σε αντιπροσωπευτικά περιστατικά.

Ο Πίνακας 6.1 συνοψίζει τη **καλύτερη** επίδοση κάθε μοντέλου στο validation set, όπως προέκυψε σε επίπεδο 3D όγκου σε 120 epochs. Οι τιμές Dice χρησιμοποιούνται ως σημείο αναφοράς για την αναλυτικότερη ποιοτική και συγκριτική συζήτηση που ακολουθεί. (μέγιστη τιμή του mean Dice ανά epoch)

Σημειώνεται ότι οι μετρικές επικάλυψης αποτυπώνουν κυρίως τη συμφωνία ως προς το εμβαδό/όγκο της πρόβλεψης και δεν εγγυώνται πάντα οπτικά σωστά όρια σε όλες τις περιπτώσεις. Για τον λόγο αυτό, τα ποσοτικά αποτελέσματα του Πίνακα 6.1 ερμηνεύονται σε συνδυασμό με τις καμπύλες εκπαίδευσης/επικύρωσης και την ποιοτική επιθεώρηση προβλέψεων έναντι ground truth στις επόμενες ενότητες.

Πίνακας 6.1: Αποτελέσματα ανά αρχιτεκτονική στο validation set.

Μοντέλο	Dice	IoU	Val Loss
U-Net	0.829	0.7109	0.3739
Attention U-Net	0.846	0.735	0.2004
DynUNet	0.846	0.7342	0.1897
UNETR	0.772	0.6345	0.2842
SwinUNETR	0.849	0.7401	0.1838
SegResNet 1	0.8601	0.7558	0.1678
SegResNet 2	0.859	0.7544	0.1806
SegMamba 1	0.8606	0.7566	0.1685
SegMamba 2	0.8581	0.7526	0.1697

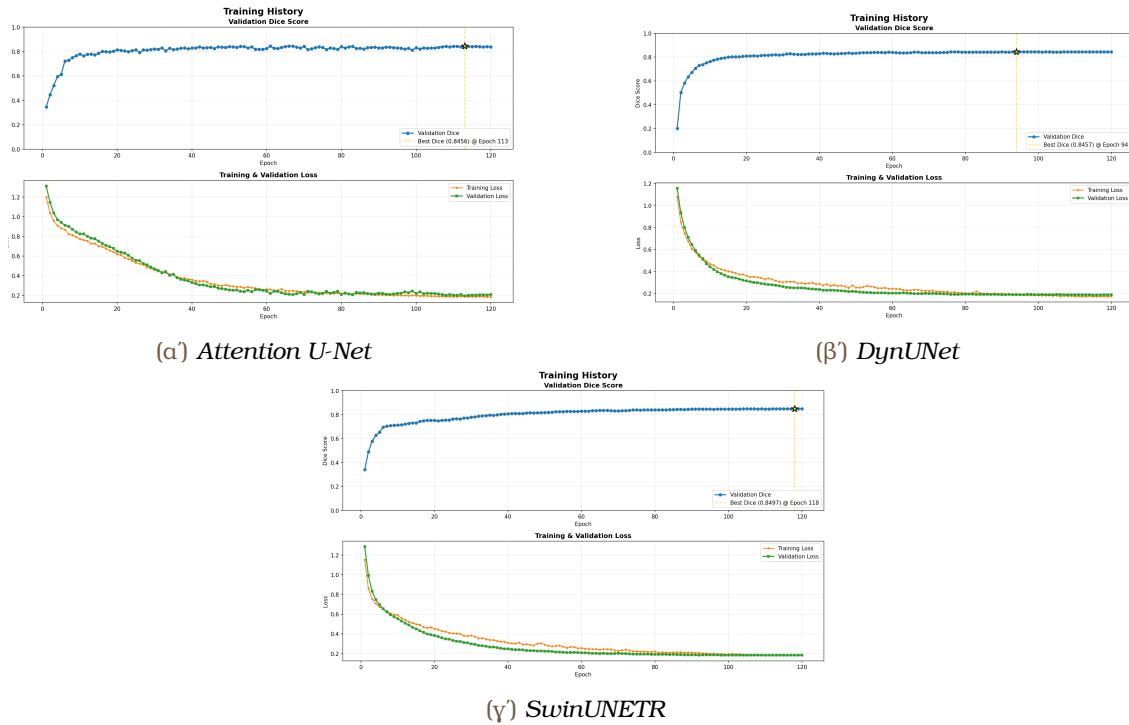
6.2 Συνοπτική κατάταξη και κύρια ευρήματα

Ξεκινώντας από τον Πίνακα 6.1, η κατάταξη των μοντέλων με βάση τη μέγιστη μέση τιμή του Dice δείχνει ότι η καλύτερη επίδοση επιτυγχάνεται από το SegMamba 1 (Dice= 0.8606) και έπειτα τα SegResNet 2 (Dice= 0.859) και SegMamba 2 (Dice= 0.8581). Οι διαφορές μέσα στα προαναφερθέντα είναι της τάξης του ≈ 0.002 – 0.003 σε Dice.

Η εικόνα αυτή επιβεβαιώνεται και από τη συμπληρωματική μετρική IoU: τα υψηλότερα IoU παρατηρούνται επίσης στα SegMamba 1 (0.7566) και SegResNet 1 (0.7558), με τα υπόλοιπα μοντέλα της κορυφής να ακολουθούν πολύ κοντά. Παράλληλα, οι τιμές validation loss είναι χαμηλότερες για τα μοντέλα με καλύτερο Dice (π.χ. SegResNet 1: 0.1678, SegMamba 1: 0.1685), γεγονός που είναι συμβατό με καλύτερη συνολική βελτιστοποίηση. Ωστόσο, επειδή το loss αποτελεί σύνθετο κριτήριο και δεν αντιστοιχεί μονοσήμαντα σε μια overlap μετρική, η τελική κατάταξη στηρίζεται πρωτίστως στο Dice (και υποστηρίζεται από IoU).

Σε επίπεδο οικογενειών αρχιτεκτονικών, παρατηρείται ότι οι αποδοτικές CNN-based προσεγγίσεις (SegResNet) και τα state space-based μοντέλα (SegMamba) υπερέχουν συνολικά των Transformer-based αρχιτεκτονικών στο συγκεκριμένο πρόβλημα/σύνολο δεδομένων. Ειδικότερα, το UNETR εμφανίζει τη χαμηλότερη επίδοση (Dice= 0.772, IoU= 0.6345), αποτελώντας σαφή outlier. Αντίθετα, το SwinUNETR λειτουργεί ως το καλύτερο Transformer-based μοντέλο (Dice= 0.849, IoU= 0.7401), ωστόσο παραμένει κάτω από την ομάδα κορυφής κατά περίπου 0.01 σε Dice. Αξίζει να σχολιάσουμε το γεγονός πως το U-Net παρότι πετυχαίνει αξιοπρεπές Dice (0.829), εμφανίζει αισθητά υψηλότερο validation loss (0.3739) σε σχέση με τα περισσότερα μοντέλα. Αυτή η ασυμφωνία υποδηλώνει ότι η πρόβλεψη μπορεί να είναι επαρκής ως προς το overlap μετά το thresholding, αλλά οι πιθανότητες εξόδου είναι λιγότερο καλά βαθμονομημένες (δηλαδή πιο «αιχμηρές» και overconfident σε λάθη).

Τέλος, οι παραλλαγές χωρητικότητας (SegResNet 1 έναντι SegResNet 2, και SegMamba 1 έναντι SegMamba 2) δείχνουν ότι η «βαρύτερη» ρύθμιση μπορεί να προσφέρει μικρό αλλά μετρήσιμο κέρδος στην επικάλυψη (π.χ. SegResNet 1: 0.8601 έναντι 0.859), χωρίς όμως να αλλάζει δραστικά την κατάταξη. Στις επόμενες ενότητες διερευνάται αν αυτές οι μικρές διαφορές συνοδεύονται από πιο σταθερή σύγκλιση ή/και πιο καθαρό οπτικό περίγραμμα στις προβλέψεις.



Σχήμα 6.1


6.3 Καμπύλες εκπαίδευσης και σταθερότητα σύγκλισης

Στα σχήματα 6.1, 6.2 και 6.3 παρουσιάζονται οι καμπύλες εκπαίδευσης για κάθε αρχιτεκτονική. Πρώτη καμπύλη αποτελεί τη μετρική Dice και η δεύτερη τα training και validation losses κατά τη διάρκεια των epochs.

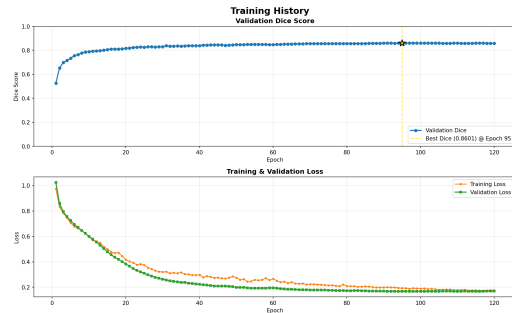
Γενική εικόνα σύγκλισης. Σε όλες σχεδόν τις CNN-βασισμένες αρχιτεκτονικές παρατηρείται **ταχεία αρχική βελτίωση** του validation Dice στα πρώτα 5-15 epochs, συγκλίνοντας σχετικά νωρίς (σταδιακή, μικρή βελτίωση) μέχρι το τέλος της εκπαίδευσης. Αυτό υποδηλώνει ότι το μοντέλο μαθαίνει γρήγορα τη χονδρική μορφολογία του πλακούντα, ενώ οι επιπλέον εποχές συμβάλλουν κυρίως σε λεπτότερη προσαρμογή (όρια, μικρές ασυνέχειες, μείωση false positives).

6.4 Ποιοτική αξιολόγηση προβλέψεων


6.5 Συζήτηση και ερμηνεία



(α') SegResNet 2 (No of Filters = 32)




(β') SegResNet 1 (No of Filters = 64)




(γ') U-Net


Σχήμα 6.2



(α') UNETR







(β') SegMamba 1 (5 layers)




(γ') SegMamba 2 (4 layers)

Σχήμα 6.3

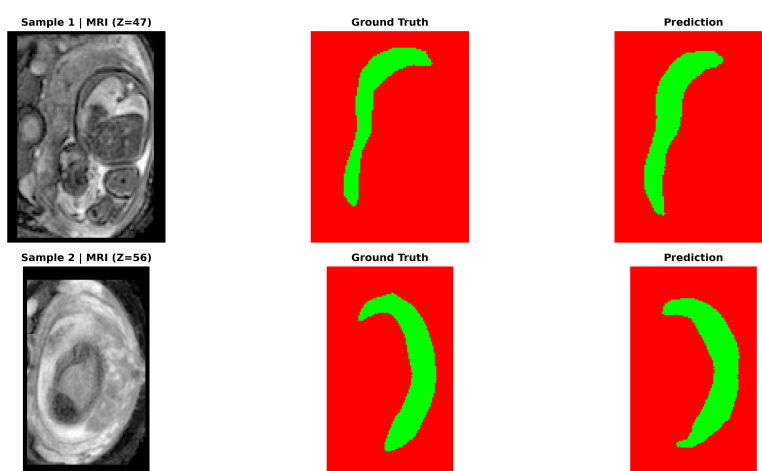
Εικόνα 6.1: *Attention U-Net*Εικόνα 6.2: *DynUNet*Εικόνα 6.3: *SwinUNETR*






Εικόνα 6.4: *SegResNet 1 (No of Filters = 64)*



Εικόνα 6.5: *SegResNet 2 (No of Filters = 32)*



Εικόνα 6.6: *U-Net*

Εικόνα 6.7: *UNETR*Εικόνα 6.8: *SegMamba 1 (5 layers)*Εικόνα 6.9: *SegMamba 2 (4 layers)*

Παράδειγμα Πίνακα

7.1 Συμπεράσματα

Τα συστήματα ομότιμων κόμβων, προκειμένου να υποστηρίξουν πιο εκφραστικές λειτουργίες αναπαράστασης και αναζήτησης δεδομένων, εξελίχθηκαν στα συστήματα ομότιμων κόμβων τα οποία βασίζονται στις τεχνολογίες του Σημασιολογικού Ιστού για την αναπαράσταση των δεδομένων μέσω σχημάτων που τα περιγράφουν (Schema-based peer-to-peer systems).

Συμπερασματικά το σύστημα που αναπτύχθηκε στα πλαίσια αυτής της διπλωματικής είναι ένα πλήρες σύστημα ομότιμων κόμβων βασισμένο σε σχήματα, το οποίο καθιστά δυνατή την αναζήτηση της πληροφορίας με ένα διαφορετικό τρόπο απ' ότι τα προϋπάρχοντα συστήματα.

7.2 Μελλοντικές Επεκτάσεις

Το σύστημα που αναπτύχθηκε στα πλαίσια αυτής της διπλωματικής εργασίας θα μπορούσε να βελτιωθεί και να επεκταθεί περαιτέρω, τουλάχιστον ως προς τρεις κατευθύνσεις. Συγκεκριμένα, αναφέρονται τα ακόλουθα :

- Ενσωμάτωση διαδικασίας επιλογής σχήματος με βάση το οποίο ο κόμβος θα συμμετέχει στο σύστημα. Έτσι όπως έχει σχεδιαστεί το σύστημα, κάθε κόμβος έχει τη δυνατότητα να δημιουργήσει πολλά σχήματα και να αποθηκεύσει δεδομένα σε περισσότερα από ένα. Ως σχήμα του κόμβου (με βάση το οποίο απαντάει τις ερωτήσεις), θεωρείται το τελευταίο στο οποίο αποθήκευσε δεδομένα. Η δυνατότητα επιλογής θα του παρείχε περισσότερη ευελιξία.
- Δυνατότητα αντιστοίχισης δεδομένων τα οποία να μην είναι αποθηκευμένα σε βάση δεδομένων αλλά σε αρχεία. Η αποδέσμευση από τη βάση δεδομένων θα έκανε το σύστημα πιο εύκολο στην εγκατάσταση και τη χρήση.
- Αξιολόγηση του συστήματος ως προς τη συμπεριφορά του αν συμμετέχει σε αυτό μεγάλος αριθμός κόμβων (scalability testing) και αν χρησιμοποιηθεί ένα πολύ μεγάλο καθολικό σχήμα. Η αξιολόγηση αυτή αφορά την ταχύτητα με την οποία ένας κόμβος παίρνει απαντήσεις σε μια ερώτηση καθώς και την ποιότητα των απαντήσεων.

Πίνακας 7.1: Πίνακας αλήθειας της λογικής συνάρτησης F

A	B	C	F
0	0	0	0
0	0	1	0
0	1	0	1
0	1	1	0
1	0	0	1
1	0	1	0
1	1	0	1
1	1	1	0

Κεφάλαιο **8**

Παράδειγμα Μαθηματικών Σχέσεων – Εκφράσεων και Αλγορίθμων

8.1 Συμπεράσματα

8.2 Μελλοντικές Επεκτάσεις

ΑΛΓΟΡΙΘΜΟΣ 8.1: Κάποιος αλγόριθμος ...

```
#include <stdio.h>
#define N 10
/* Block
 * comment */

int main()
{
    int i;

    // Line comment.
    puts("Hello world!");

    for (i = 0; i < N; i++)
    {
        puts("LaTeX is also great for programmers!");
    }

    return 0;
}
```

Μέρος **III**

Επίλογος

Κεφάλαιο **9**

Επίλογος

9.1 Συμπεράσματα

9.2 Μελλοντικές Επεκτάσεις

Παραρτήματα

Παράδειγμα Παραρτήματος

Α.1 Πρώτη ενότητα

Τα συστήματα ομότιμων κόμβων, προκειμένου να υποστηρίξουν πιο εκφραστικές λειτουργίες αναπαράστασης και αναζήτησης δεδομένων, εξελίχθηκαν στα συστήματα ομότιμων κόμβων τα οποία βασίζονται στις τεχνολογίες του Σημασιολογικού Ιστού για την αναπαράσταση των δεδομένων μέσω σχημάτων που τα περιγράφουν (Schema-based peer-to-peer systems).

Συμπερασματικά το σύστημα που αναπτύχθηκε στα πλαίσια αυτής της διπλωματικής είναι ένα πλήρες σύστημα ομότιμων κόμβων βασισμένο σε σχήματα, το οποίο καθιστά δυνατή την αναζήτηση της πληροφορίας με ένα διαφορετικό τρόπο απ' ότι τα προϋπάρχοντα συστήματα.

Α.2 Μελλοντικές Επεκτάσεις

Το σύστημα που αναπτύχθηκε στα πλαίσια αυτής της διπλωματικής εργασίας θα μπορούσε να βελτιωθεί και να επεκταθεί περαιτέρω, τουλάχιστον ως προς τρεις κατευθύνσεις. Συγκεκριμένα, αναφέρονται τα ακόλουθα :

- Ενσωμάτωση διαδικασίας επιλογής σχήματος με βάση το οποίο ο κόμβος θα συμμετέχει στο σύστημα. Έτσι όπως έχει σχεδιαστεί το σύστημα, κάθε κόμβος έχει τη δυνατότητα να δημιουργήσει πολλά σχήματα και να αποθηκεύσει δεδομένα σε περισσότερα από ένα. Ως σχήμα του κόμβου (με βάση το οποίο απαντάει τις ερωτήσεις), θεωρείται το τελευταίο στο οποίο αποθήκευσε δεδομένα. Η δυνατότητα επιλογής θα του παρείχε περισσότερη ευελιξία.
- Δυνατότητα αντιστοίχισης δεδομένων τα οποία να μην είναι αποθηκευμένα σε βάση δεδομένων αλλά σε αρχεία. Η αποδέσμευση από τη βάση δεδομένων θα έκανε το σύστημα πιο εύκολο στην εγκατάσταση και τη χρήση.
- Αξιολόγηση του συστήματος ως προς τη συμπεριφορά του αν συμμετέχει σε αυτό μεγάλος αριθμός κόμβων (scalability testing) και αν χρησιμοποιηθεί ένα πολύ μεγάλο καθολικό σχήμα. Η αξιολόγηση αυτή αφορά την ταχύτητα με την οποία ένας κόμβος παίρνει απαντήσεις σε μια ερώτηση καθώς και την ποιότητα των απαντήσεων.

Πίνακας Α'.1: Πίνακας αλήθειας της λογικής συνάρτησης F

A	B	C	F
0	0	0	0
0	0	1	0
0	1	0	1
0	1	1	0
1	0	0	1
1	0	1	0
1	1	0	1
1	1	1	0

Παράρτημα Β'

Απόδειξη της σχέσης (8.1)

Στο κεφάλαιο αυτό παρουσιάζεται η μελέτη που έγινε για την υλοποίηση του συστήματος. Αρχικά περιγράφεται η αρχιτεκτονική του συστήματος και γίνεται ο διαχωρισμός του στα επιμέρους υποσυστήματα, ενώ στη συνέχεια περιγράφονται οι εφαρμογές του συστήματος. ελένη


Β'.1 Ανάλυση - περιγραφή αρχιτεκτονικής

Στην ενότητα αυτή παρουσιάζεται η ανάλυση του συστήματος και ο χωρισμός του σε υποσυστήματα όσον αφορά την αρχιτεκτονική.

Β'.1.1 Διαχωρισμός υποσυστημάτων

Το σύστημα αποτελείται από τους απλούς κόμβους και ένα κόμβο διαχειριστή. Στο σημείο αυτό αναλύουμε το σύστημα ενός απλού κόμβου, το οποίο αποτελείται από τα εξής υποσυστήματα :

- Υποσύστημα δημιουργίας σχήματος.
- Υποσύστημα ενσωμάτωσης δεδομένων στο σχήμα.
- Υποσύστημα επικοινωνίας κόμβου.



Σχήμα Β'.1: Προσομοίωση Πύλης NOR

Το Σχήμα Β'.1 απεικονίζει

Β'.1.2 Περιγραφή υποσυστημάτων

Παρακάτω δίνεται λεπτομερής περιγραφή για καθένα από τα συστήματα που αναφέραμε. Η περιγραφή αυτή γίνεται με βάση τα διαγράμματα ροής δεδομένων.

Υποσύστημα δημιουργίας σχήματος

Το υποσύστημα αυτό

Παραδείγματα Βιβλιογραφικών Αναφορών

Τύπος βιβλιογραφικής πηγής	Αριθμός αναφοράς
Βιβλίο ξενόγλωσσο	[;]
Βιβλίο ελληνικό	[;]
Άρθρο σε επιστημονικό περιοδικό	[;]
Παρουσίαση σε επιστημονικό συνέδριο	[;]
Ιστοσελίδα	[;]
Διπλωματική εργασία	[;]
Πτυχιακή εργασία	[;]
Μεταπτυχιακή διπλωματική εργασία	[;]
Διδακτορική διατριβή	[;]
Δίπλωμα ευρεσιτεχνίας (πατέντα)	[;]
Τεχνική αναφορά	[;]

Δημιουργία Ευρετηρίου

Δείτε το περιεχόμενο του αρχείου appD.tex για τρόπους ορισμού ελληνικών και ξενόγλωσσων όρων ευρετηρίου.

Παράρτημα **Ε'**

Εισαγωγή Εικόνων

Δείτε το περιεχόμενο του αρχείου appE.tex για τον τρόπο εισαγωγής εικόνων.

Βιβλιογραφία

- [1] Kaiming He, Xiangyu Zhang, Shaoqing Ren και Jian Sun. *Deep Residual Learning for Image Recognition*. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, σελίδες 770–778, 2016.
- [2] A Alansary, K Kamnitsas, A Davidson, R Khlebnikov, M Rajchl, C Malamateniou, M Rutherford, JV Hajnal, B Glocker, D Rueckert και et al. *Fast Fully Automatic Segmentation of the Human Placenta from Motion Corrupted MRI*. 2016.
- [3] Guotai Wang, Maria A. Zuluaga, Rosalind Pratt, Michael Aertsen, Tom Doel, Maria Klusmann, Anna L. David, Jan Deprest, Tom Vercauteren και Sébastien Ourselin. *Slic-Seg: A minimally interactive segmentation of the placenta from sparse and motion-corrupted fetal MRI in multiple views*. *Medical Image Analysis*, 34:137–147, 2016.
Σπεσιαλ Ισσυε ον τηε 2015 όνφερενσε ον Μεδισαλ Ιμαγε όμπτυνγ ανδ όμπττερ Αοοιστεδ Ιντερεντιον.
- [4] Maysam Shahedi, Catherine Y. Spong, James D. Dormer, Quyen N. Do, Yin Xi, Matthew A. Lewis, Christina Herrera, Ananth J. Madhuranthakam, Diane M. Twickler και Baowei Fei. *Deep learning-based segmentation of the placenta and uterus on MR images*. *Journal of Medical Imaging*, 8(5):054001, 2021.
- [5] Olaf Ronneberger, Philipp Fischer και Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. *Medical Image Computing and Computer-Assisted Intervention - MICCAI 2015*, τόμος 9351 στο *Lecture Notes in Computer Science*, σελίδες 234–241. Springer, 2015.
- [6] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser και Illia Polosukhin. *Attention Is All You Need*. arXiv preprint, 2017.
- [7] Ali Hatamizadeh, Yucheng Tang, Vishwesh Nath, Dong Yang, Andriy Myronenko, Holger R. Roth και Daguang Xu. *UNETR: Transformers for 3D Medical Image Segmentation*. *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, σελίδες 574–584, 2022.
- [8] Ali Hatamizadeh, Vishwesh Nath, Yucheng Tang, Dong Yang, Holger R. Roth και Daguang Xu. *Swin UNETR: Swin Transformers for Semantic Segmentation of Brain Tumors in MRI Images*. *Brainlesion: Glioma, Multiple Sclerosis, Stroke and Traumatic Brain Injuries (BrainLes 2021)*, τόμος 12962 στο *Lecture Notes in Computer Science*, σελίδες 272–284. Springer, 2022.

- [9] Albert Gu, Tri Dao και others. *Mamba: Linear-Time Sequence Modeling with Selective State Spaces*. arXiv preprint, 2023.
- [10] Zhaohu Xing, Tian Ye, Yijun Yang, Guang Liu και Lei Zhu. *SegMamba: Long-range Sequential Modeling Mamba For 3D Medical Image Segmentation*. *Medical Image Computing and Computer Assisted Intervention - MICCAI 2024*, τόμος 15008 στο *Lecture Notes in Computer Science*, σελίδες 578–588. Springer, 2024.
- [11] M. Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, Benjamin Murray, Andriy Myronenko, Can Zhao, Dong Yang και others. *MONAI: An open-source framework for deep learning in healthcare*. arXiv preprint, 2022.
- [12] Andriy Myronenko. *3D MRI brain tumor segmentation using autoencoder regularization*. arXiv preprint, 2018.
- [13] Ozan Oktay, Jo Schlemper, Loic Le Folgoc, Matthew Lee, Mattias Heinrich, Kazunari Misawa, Kensaku Mori, Steven McDonagh, Nils Y. Hammerla, Bernhard Kainz, Ben Glocker και Daniel Rueckert. *Attention U-Net: Learning Where to Look for the Pancreas*. arXiv preprint, 2018.
- [14] Graham J. Burton και Eric Jauniaux. *What is the placenta? A guide for clinicians*. *American Journal of Obstetrics and Gynecology*, 2015.
- [15] Emin Maltepe και Susan J. Fisher. *Placenta: the forgotten organ*. *Annual Review of Cell and Developmental Biology*, 31:523–552, 2015.
- [16] Naveen M. Gude, Clare T. Roberts, Bill Kalionis και Roger G. King. *Growth and function of the normal human placenta*. *Thrombosis Research*, 114(5-6):397–407, 2004.
- [17] Charlotte H. J. R. Jansen, Arnoud W. Kastelein, C. Emily Kleinrouweler, Elisabeth Van Leeuwen, Kees H. De Jong, Eva Pajkrt και Cornelis J. F. Van Noorden. *Development of placental abnormalities in location and anatomy*. *Acta Obstetrica et Gynecologica Scandinavica*, 99(8):983–993, 2020.
- [18] Ivo Brosens, Robert Pijnenborg, Liesbeth Vercruysse και Roberto Romero. *The “Great Obstetrical Syndromes” are associated with disorders of deep placentation*. *American Journal of Obstetrics and Gynecology*, 204(3):193–201, 2011.
- [19] Emin Maltepe, Anna I. Bakardjiev και Susan J. Fisher. *The placenta: transcriptional, epigenetic, and physiological integration during development*. *The Journal of Clinical Investigation*, 120(4):1016–1025, 2010.
- [20] Bordoni B. Herrick EJ. *Embryology, Placenta*.
- [21] Giuseppe Morgese, Samuele Salti, Lukas Bednar και Daniel Soukup. *Mitigating the effects of severe imbalance in multi-class semantic segmentation*. Μεταπτυχιακή διπλωματική εργασία, University of Bologna, 2024.

- [22] Konstantinos Kamnitsas, Christian Ledig, Virginia F.J. Newcombe, Joanna P. Simpson, Andrew D. Kane, David K. Menon, Daniel Rueckert και Ben Glocker. *Efficient multi-scale 3D CNN with fully connected CRF for accurate brain lesion segmentation*. *Medical Image Analysis*, 36:61–78, 2017.
- [23] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen και Klaus H. Maier-Hein. *Nature Methods*, (2):203–211, 2020.
- [24] Maysam Shahedi, James D Dormer, Guyen N Do, Yin Xi, Matthew A Lewis, Christina L Herrera, Catherine Y Spong, Ananth J Madhuranthakam, Diane M Twickler και Baowei Fei. *Automatic segmentation of uterine cavity and placenta on MR images using deep learning*. *Proceedings of SPIE-the International Society for Optical Engineering*, τόμος 12036, σελίδα 1203611, 2022.
- [25] Yongkai Liu, Fatemeh Zabihollahy, Ran Yan, Brian Lee, Carla Janzen, Sherin U Devaskar και Kyunghyun Sung. *Evaluation of spatial attentive deep learning for automatic placental segmentation on longitudinal MRI*. *Journal of Magnetic Resonance Imaging*, 57(5):1533–1540, 2023.
- [26] E. Mark Haacke, Robert W. Brown, Michael R. Thompson και Ramesh Venkatesan. *Magnetic Resonance Imaging: Physical Principles and Sequence Design*. Wiley-Liss, 1999.
- [27] Donald W. McRobbie, Elizabeth A. Moore, Martin J. Graves και Martin R. Prince. *MRI from Picture to Proton*. Cambridge University Press, 2η έκδοση, 2006.
- [28] Nicholas J. Tustison, Brian B. Avants, Philip A. Cook, Yuanjie Zheng, Alexander Egan, Paul A. Yushkevich και James C. Gee. *N4ITK: Improved N3 Bias Correction*. *IEEE Transactions on Medical Imaging*, 29(6):1310–1320, 2010.
- [29] Sabir Muhammad και Jing Zhang. *Segmentation of Liver Tumors by Monai and PyTorch in CT Images with Deep Learning Techniques*. *Applied Sciences*, 14(12), 2024.
- [30] Geert Litjens, Thijs Kooi, Babak Ehteshami Bejnordi, Arnaud Arindra Adiyoso Setio, Francesco Ciompi, Mohsen Ghafoorian, Jeroen A. W. M. van der Laak, Bram van Ginneken και Clara I. Sánchez. *A survey on deep learning in medical image analysis*. *Medical Image Analysis*, 42:60–88, 2017.
- [31] Ian Goodfellow, Yoshua Bengio και Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [32] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Springer, 2006.
- [33] Carole H. Sudre, Wenqi Li, Tom Vercauteren, Sebastien Ourselin και M. Jorge Cardoso. *Generalised Dice Overlap as a Deep Learning Loss Function for Highly Unbalanced Segmentations*. *Deep Learning in Medical Image Analysis and Multimodal Learning for Clinical Decision Support (DLMIA 2017)*, τόμος 10553 στο *Lecture Notes in Computer Science*, σελίδες 240–248. Springer, 2017.

- [34] Fausto Milletari, Nassir Navab και Seyed Ahmad Ahmadi. *V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation*. arXiv preprint, 2016.
- [35] Charu C Aggarwal και others. *Neural networks and deep learning*, τόμος 10. Springer, 2018.
- [36] Alex Krizhevsky, Ilya Sutskever και Geoffrey E. Hinton. *ImageNet Classification with Deep Convolutional Neural Networks*. *Advances in Neural Information Processing Systems (NeurIPS)*, 2012.
- [37] Jonathan Long, Evan Shelhamer και Trevor Darrell. *Fully Convolutional Networks for Semantic Segmentation*. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, σελίδες 3431–3440, 2015.
- [38] Özgün Cicek, Ahmed Abdulkadir, Soeren S. Lienkamp, Thomas Brox και Olaf Ronneberger. *3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation*. *Medical Image Computing and Computer-Assisted Intervention - MICCAI 2016*, τόμος 9901 στο *Lecture Notes in Computer Science*, σελίδες 424–432. Springer, 2016.
- [39] Sergey Ioffe και Christian Szegedy. *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. 2015.
- [40] Yuxin Wu και Kaiming He. *Group Normalization*. 2018.
- [41] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit και Neil Houlsby. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale*. arXiv preprint, 2021.
- [42] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin και Baining Guo. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. arXiv preprint, 2021.
- [43] Sinong Wang, Belinda Z. Li, Madian Khabsa, Han Fang και Hao Ma. *Linformer: Self-Attention with Linear Complexity*. 2020.
- [44] Krzysztof Choromanski και others. *Rethinking Attention with Performers*. 2021.
- [45] Albert Gu, Karan Goel και Christopher Ré. *Efficiently Modeling Long Sequences with Structured State Spaces*. *International Conference on Learning Representations (ICLR)*, 2022.
- [46] Karan Goel, Albert Gu, Chris Donahue και Christopher Ré. *It's Raw! Audio Generation with State-Space Models*. *International Conference on Machine Learning (ICML)*, 2022.
- [47] Ilya Loshchilov και Frank Hutter. *Decoupled Weight Decay Regularization*. arXiv preprint, 2019.

- [48] *Learning Rate Schedulers in PyTorch*. Αρχειοθετημένο: 2024-06-10.
- [49] Project MONAI. *MONAI Documentation*. <https://monai-dev.readthedocs.io/en/new-doc-theme/api.html>, 2025. Αρχειοθετημένο: 2026-01-25.
- [50] Project MONAI. *Project MONAI: MONAI (GitHub Repository)*. <https://github.com/Project-MONAI/MONAI>, 2025. Αρχειοθετημένο: 2026-01-25.
- [51] Zhaohu Xing, Tian Ye, Yijun Yang, Guang Liu και Lei Zhu. *SegMamba: Official Implementation (GitHub Repository)*. <https://github.com/ge-xing/SegMamba>, 2024. Αρχειοθετημένο: 2026-01-25.
- [52] Fabian Isensee, Paul F. Jaeger, Simon A. A. Kohl, Jens Petersen και Klaus H. Maier-Hein. *nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation*. *Nature Methods*, 18(2):203–211, 2021.
- [53] Project MONAI. *MONAI Transforms Documentation*. <https://monai-dev.readthedocs.io/en/new-doc-theme/transforms.html#dictionary-transforms>, 2024. Αρχειοθετημένο: 2024-06-10.
- [54] Leslie N. Smith. *Cyclical Learning Rates for Training Neural Networks*, 2017.

Συντομογραφίες - Αρκτικόλεξα - Ακρωνύμια

βλπ	βλέπε
κ.λπ.	και λοιπά
κ.ο.κ	και ούτω καθεξής
ΤΕΙ	Τεχνολογικό Εκπαιδευτικό Ίδρυμα
BPF	Band Pass Filter

Απόδοση ξενόγλωσσων όρων

Απόδοση

αδερφός
αμεταβλητότητα
ανάκτηση πληροφορίας
αντιμεταθετικότητα
απόγονος
απορρόφηση
βάση δεδομένων
γνώρισμα
διαπροσωπεία
διαφορά
δικτυακός κατάλογος
δικτυωτή δομή
δομικές επερωτήσεις
δομικές σχέσεις
δομικό σχήμα
εγκυρότητα
ένωση

Ξενόγλωσσος όρος

sibling
idempotency
information retrieval
commutativity
descendant
absorption
database
attribute
interface
difference
portal catalog
lattice
structural queries
structural relationships
schema
validity
union

